BỘ CÔNG THƯƠNG

ĐẠI HỌC CÔNG NGHIỆP HÀ NỘI

---------- ----------

BÁO CÁO BÀI TẬP LỚN

HỌC PHẦN DỰ BÁO VÀ PHÂN TÍCH DỮ LIỆU

ĐỀ TÀI

XÂY DỰNG VÀ ỨNG MÔ HÌNH HỌC MÁY
ĐỂ PHÂN TÍCH VÀ DỰ ĐOÁN CỔ PHIẾU FPT

Giảng viên hướng dẫn	:	**ThS. Trương Hoàng Giang**
Lớp	:	20251AA6061001
Nhóm	:	01
Danh sách các thành viên	:	1. Nguyễn Hồng Quân - 2023602671
		2. Khổng Vũ Huy - 2023607308
		3. Trần Đức Lương - 2023604068
		4. Nguyễn Anh Tú - 2023606605
		5. Lý Công Long - 2023605152

HÀ NỘI, 12/2025

BỘ CÔNG THƯƠNG

ĐẠI HỌC CÔNG NGHIỆP HÀ NỘI

---------- ----------

BÁO CÁO BÀI TẬP LỚN

HỌC PHẦN DỰ BÁO VÀ PHÂN TÍCH DỮ LIỆU

ĐỀ TÀI

XÂY DỰNG VÀ ỨNG MÔ HÌNH HỌC MÁY
ĐỂ PHÂN TÍCH VÀ DỰ ĐOÁN CỔ PHIẾU FPT

Giảng viên hướng dẫn	:	**ThS. Trương Hoàng Giang**
Lớp	:	20251AA6061001
Nhóm	:	01
Danh sách các thành viên	:	1. Nguyễn Hồng Quân - 2023602671
		2. Khổng Vũ Huy - 2023607308
		3. Trần Đức Lương - 2023604068
		4. Nguyễn Anh Tú - 2023606605
		5. Lý Công Long - 2023605152

HÀ NỘI, 12/2025

Bảng đánh giá công việc các thành viên trong Nhóm 1

Môn học :Dự báo và phân tích dữ liệu

Người hướng dẫn: Ths. Trương Hoàng Giang

Mã môn : AA6053

STT	Họ và tên	MSV	Nội dung công việc cụ thể	Mứ độ hoàn thành	Chữ ký
1	Lý Công Long	2023605152	Tính cấp thiết của đề tài. Mục tiêu nghiên cứu, Câu hỏi nghiên cứu, Đối tượng và phạm vi nghiên cứu, Phương pháp nghiên cứu, Ý nghĩa khoa học và thực tiễn của đề tài, Kết cấu của đề tài.	100%	
2	Trần Đức Lương	2023604068	Chỉnh sửa file Word, lời mở đầu, lời cảm ơn, mục lục, danh mục hình ảnh, tham khảo, tổng quan về thị trường chứng khoán VIệt Nam, khái niệm và đặc trưng của chuỗi thời gian tài chính.	100%	
3	Khổng Vũ Huy	2023607308	Giả thuyết bước đi ngẫu nhiên rwh (random walk hypothesis), mô hình lstm (long short-term memory), mô hình xgboost (extreme gradient boosting), mô hình lai (Hybrid Model) và lý thuyết phân rã sai số, các chỉ tiêu đánh giá mô hình dự báo.	100%	

4	Nguyễn Hồng Quân	2023602671	Nguồn dữ liệu, mô tả dữ liệu, tiền xử lý dữ liệu, mô tả và thống kê dữ liệu, xây dựng mô hình lstm cho cổ phiếu fpt, đánh giá độ phù hợp của mô hình lstm và mô hình lai, kết quả dự báo giá cổ phiếu FPT giai đoạn 2016–2026.	100%	
5	Nguyễn Anh Tú	2023606605	Tóm tắt kết quả chính của nghiên cứu, kết luận và trả lời câu hỏi nghiên cứu, hàm ý chính sách và quản trị, hạn chế nghiên cứu và hướng nghiên cứu tiếp theo.	100%	

LỜI CẢM ƠN

Nhóm chúng em xin gửi lời cảm ơn chân thành và sâu sắc đến thầy Trương Hoàng Giang - người đã tận tình hướng dẫn, định hướng và hỗ trợ nhóm trong suốt quá trình thực hiện bài báo cáo với đề tài "Xây dựng và ứng mô hình học máy để phân tích và dự đoán cổ phiếu FPT".

Nhờ sự chỉ bảo chi tiết, những góp ý chuyên môn quý báu cùng sự động viên kịp thời của thầy, nhóm đã có thể hoàn thiện bài nghiên cứu một cách hệ thống và khoa học hơn. Những kiến thức và kinh nghiệm mà thầy truyền đạt không chỉ giúp nhóm hiểu rõ hơn về mô hình học máy trong phân tích tài chính mà còn rèn luyện tư duy nghiên cứu và kỹ năng làm việc nhóm.

Một lần nữa, nhóm xin trân trọng cảm ơn thầy vì sự hướng dẫn tận tâm và trách nhiệm của thầy trong suốt quá trình thực hiện đề tài.

MỤC LỤC

DANH MỤC HÌNH ẢNH **7**

LỜI MỞ ĐẦU **8**

CHƯƠNG 1: GIỚI THIỆU **9**

1.1. Tính cấp thiết của đề tài 9

1.1.1. Vai trò của thị trường chứng khoán và thách thức trong công tác dự báo 9

1.1.2. FPT và bài toán định giá trong ngành công nghệ thông tin 10

1.1.3. Khoảng trống phương pháp luận 11

1.2. Mục tiêu nghiên cứu 12

1.2.1 Mục tiêu tổng quát 12

1.2.2 Mục tiêu cụ thể 12

1.3. Câu hỏi nghiên cứu 12

1.4. Đối tượng và phạm vi nghiên cứu 13

1.4.1 Đối tượng nghiên cứu 13

1.4.2 Phạm vi nghiên cứu 13

1.5. Phương pháp nghiên cứu 14

1.6. Ý nghĩa khoa học và thực tiễn của đề tài 15

1.6.1. Ý nghĩa khoa học: 15

1.6.2. Ý nghĩa thực tiễn 15

1.7. Kết cấu của đề tài 15

KẾT LUẬN CHƯƠNG 1 16

CHƯƠNG 2: CƠ SỞ LÝ LUẬN VÀ TỔNG QUAN NGHIÊN CỨU **17**

2.1. Tổng quan về thị trường chứng khoán Việt Nam 17

2.2. Lý thuyết nền tảng về dự báo chuỗi thời gian tài chính 17

2.2.1. Khái niệm và Đặc trưng của Chuỗi thời gian Tài chính 17
2.2.2. Tính dừng (Stationarity) và Kiểm định Nghiệm đơn vị 18
2.2.3. Giả thuyết Bước đi ngẫu nhiên RWH (Random Walk Hypothesis). 19
2.3. Mô hình LSTM (Long Short - Term Memory)..... 20
2.3.1. Cấu trúc mô hình 21
2.3.2. Giả định của mô hình 21
2.3.3. Quy trình xây dựng mô hình LSTM trong dự báo giá cổ phiếu 22
2.3.4. Ưu điểm và hạn chế của mô hình LSTM 22
2.4. Mô hình XGBoost (Extreme Gradient Boosting) 23
2.4.1. Giới thiệu thuật toán..... 23
2.4.2. Cơ chế hoạt động và Hàm mục tiêu 23
2.5. Mô hình lai (Hybrid Model) và lý thuyết phân rã sai số..... 24
2.5.1. Cơ sở lý thuyết của Phương pháp Lai ghép 24
2.5.2. Tổng quan các nghiên cứu thực nghiệm 25
2.5.3. Khoảng trống nghiên cứu (Research Gap)..... 25
2.6. Các chỉ tiêu đánh giá mô hình dự báo 26
KẾT LUẬN CHƯƠNG 2..... 27
CHƯƠNG 3: THỰC NGHIỆM VÀ THẢO LUẬN 28
3.1 Nguồn dữ liệu..... 28
3.2 Mô tả dữ liệu 28
3.3. Tiền xử lý dữ liệu 29
3.4. Mô tả và thống kê dữ liệu..... 29
3.4.1 Phân tích dư liệu chuỗi thời gian của dữ liệu cổ phiếu FPT..... 31
3.5. Xây dựng mô hình LSTM cho cổ phiếu FPT..... 32
3.6. Đánh giá độ phù hợp của mô hình LSTM và mô hình lai 34

3.7. Kết quả dự báo giá cổ phiếu FPT giai đoạn 2016–2026 36
3.7.1 So sánh giá dự báo và giá thực tế niêm yết trên sàn chứng khoán của FPT 39
CHƯƠNG 4: KẾT LUẬN VÀ HÀM Ý 41
4.1. Tóm tắt kết quả chính của nghiên cứu 41
4.2. Kết luận và trả lời câu hỏi nghiên cứu 41
4.3. Hàm ý chính sách và quản trị 43
4.4. Hạn chế nghiên cứu và hướng nghiên cứu tiếp theo 44
4.4.1. Hạn chế nghiên cứu 44
4.4.2. Hướng nghiên cứu tiếp theo 44
Danh mục tài liệu tham khảo 46

DANH MỤC HÌNH ẢNH

Hình 3.4. Biểu đồ giá cổ phiếu FPT 30
Hình 3.4.1. Phân tích dư liệu chuỗi thời gian của dữ liệu cổ phiếu FPT 31
Hình 3.6. Kết quả của RMSE và MAE trên tập Train và Test 35
Hình 3.6. Giá thực tế và giá dự báo trên tập test từ năm 2016-2026 36
Hình 3.7. Giá thực tế và giá dự báo 10 ngày tiếp theo 38
Hình 3.7.1. So sánh kết quả dự báo với thực tế 39

LỜI MỞ ĐẦU

Trong bối cảnh chuyển đổi số và sự phát triển nhanh chóng của thị trường tài chính, thị trường chứng khoán Việt Nam ngày càng trở thành kênh đầu tư quan trọng đối với cá nhân và tổ chức. Giá cổ phiếu không chỉ phản ánh hiệu quả hoạt động của doanh nghiệp mà còn chịu tác động từ nhiều yếu tố như điều kiện kinh tế vĩ mô, tâm lý nhà đầu tư, dòng vốn thị trường và các biến động toàn cầu. Do đó, việc dự báo xu hướng giá cổ phiếu có ý nghĩa quan trọng trong hỗ trợ ra quyết định đầu tư, quản trị rủi ro và xây dựng chiến lược tài chính hiệu quả.

Tuy nhiên, dự báo giá cổ phiếu là một bài toán khó do dữ liệu tài chính mang tính biến động cao, không dừng và tồn tại cả quan hệ tuyến tính lẫn phi tuyến. Các mô hình thống kê truyền thống như ARIMA có khả năng mô hình hóa tốt cấu trúc tuyến tính của chuỗi thời gian nhưng còn hạn chế khi xử lý các biến động phi tuyến phức tạp. Ngược lại, các phương pháp học sâu, đặc biệt là mô hình Long Short-Term Memory (LSTM), cho phép học các phụ thuộc dài hạn và các mẫu biến động phi tuyến trong dữ liệu.

Hiện nay, LSTM (Long Short-Term Memory) được ứng dụng rộng rãi trong các bài toán dự báo nhờ khả năng xử lý dữ liệu chuỗi thời gian và ghi nhớ phụ thuộc dài hạn. Trong lĩnh vực tài chính, LSTM được dùng để dự báo giá cổ phiếu, tỷ giá, doanh thu và xu hướng thị trường dựa trên dữ liệu lịch sử. Trong kinh doanh và quản trị, mô hình này hỗ trợ dự báo nhu cầu sản phẩm, quản lý tồn kho và lập kế hoạch sản xuất.

Xuất phát từ thực tiễn đó, đề tài "Xây dựng và ứng mô hình học máy để phân tích và dự đoán cổ phiếu FPT" thông qua việc sử dụng mô hình lai (Hybrid Model) kết hợp giữa Long Short-Term Memory (LSTM) và XGBoost được thực hiện nhằm đánh giá khả năng mô hình dự báo trong thị trường chứng khoán Việt Nam, đồng thời cung cấp công cụ tham khảo cho nhà đầu tư và nghiên cứu học thuật.

CHƯƠNG 1: GIỚI THIỆU

1.1. Tính cấp thiết của đề tài

1.1.1. Vai trò của thị trường chứng khoán, thách thức trong công tác dự báo

Trong bối cảnh chuyển đổi số và hội nhập tài chính quốc tế ngày càng sâu rộng, thị trường chứng khoán được xem là cấu phần cốt lõi của hệ thống tài chính hiện đại. Thị trường không chỉ thực hiện chức năng huy động và phân bổ nguồn vốn trung – dài hạn cho doanh nghiệp và Chính phủ, mà còn đóng vai trò như một cơ chế phản ánh kỳ vọng của nhà đầu tư đối với triển vọng tăng trưởng, môi trường vĩ mô và mức độ ổn định kinh tế. Do đó, biến động giá cổ phiếu thường được sử dụng như một chỉ báo quan trọng về "sức khỏe" của nền kinh tế. Đối với các chủ thể tham gia thị trường, năng lực dự báo xu hướng giá có ý nghĩa thiết yếu trong việc tối ưu hóa lợi nhuận kỳ vọng và quản trị rủi ro danh mục đầu tư (Fama, 1970).

Tuy nhiên, dự báo giá cổ phiếu là một bài toán phức tạp do đặc trưng nhiễu, không dừng và biến động mạnh của chuỗi thời gian tài chính. Giá cổ phiếu chịu ảnh hưởng đồng thời của nhiều nhân tố như thông tin nội tại doanh nghiệp, điều kiện kinh tế vĩ mô, chính sách tiền tệ, cũng như yếu tố tâm lý và kỳ vọng của nhà đầu tư. Theo Giả thuyết Thị trường Hiệu quả (Efficient Market Hypothesis – EMH), giá chứng khoán đã phản ánh đầy đủ mọi thông tin sẵn có, khiến biến động giá mang tính ngẫu nhiên và khó có thể dự đoán dựa trên dữ liệu lịch sử (Fama, 1970). Dưới góc nhìn này, khả năng xây dựng mô hình dự báo tạo ra lợi nhuận vượt trội một cách bền vững bị đặt trong trạng thái hoài nghi.

Mặc dù vậy, các nghiên cứu trong lĩnh vực tài chính hành vi đã chỉ ra rằng thị trường không phải lúc nào cũng vận hành hoàn toàn hiệu quả. Những thiên lệch nhận thức như quá tự tin, hành vi bầy đàn hay phản ứng chậm trước thông tin mới có thể tạo ra sai lệch tạm thời giữa giá thị trường và giá trị nội tại (Shiller, 2003). Đồng thời, sự tồn tại của các chu kỳ kinh tế và hiệu ứng theo mùa cho thấy dữ liệu giá cổ phiếu có thể chứa đựng cấu trúc phụ thuộc và các mẫu hình phi tuyến, mở ra khả năng ứng dụng các phương pháp phân tích và dự báo nâng cao.

Đối với các thị trường mới nổi, mức độ biến động cao, thanh khoản chưa đồng đều và sự phụ thuộc vào dòng vốn quốc tế càng làm gia tăng tính bất định của chuỗi giá. Các cú sốc ngoại sinh như thay đổi chính sách lãi suất toàn cầu, biến động tỷ giá hay rủi ro địa chính trị có thể gây ra các biến động đột ngột trong ngắn hạn. Trong bối cảnh đó, các mô hình tuyến tính truyền thống có thể gặp hạn chế khi giả định về tính ổn định và quan hệ tuyến tính không còn được đảm bảo. Vì vậy, xu hướng kết hợp các phương

pháp kinh tế lượng truyền thống với các kỹ thuật học máy hiện đại nhằm khai thác đặc điểm phi tuyến và khả năng học biểu diễn từ dữ liệu đang ngày càng được chú trọng, với kỳ vọng cải thiện độ chính xác dự báo và hỗ trợ quá trình ra quyết định đầu tư trong môi trường nhiều biến động (Zhang, 2003; Chen & Guestrin, 2016).

1.1.2. FPT và bài toán định giá trong ngành công nghệ thông tin

Trong khuôn khổ nghiên cứu này, cổ phiếu của FPT Corporation (HOSE: FPT) được lựa chọn làm đối tượng phân tích tiêu biểu cho nhóm doanh nghiệp công nghệ thông tin tại thị trường Việt Nam. FPT là một trong những tập đoàn công nghệ lớn nhất Việt Nam, hoạt động trong các lĩnh vực cốt lõi như xuất khẩu phần mềm, dịch vụ công nghệ thông tin, viễn thông và giáo dục. Với chiến lược mở rộng thị trường quốc tế, đặc biệt tại Nhật Bản, Hoa Kỳ và châu Âu, FPT duy trì tốc độ tăng trưởng doanh thu và lợi nhuận ổn định trong nhiều năm gần đây. Nhờ quy mô vốn hóa lớn và thanh khoản cao, cổ phiếu FPT thường được xếp vào nhóm cổ phiếu dẫn dắt ngành công nghệ, thu hút sự quan tâm đáng kể của cả nhà đầu tư trong nước và khối ngoại (FPT Corporation, 2024).

Tuy nhiên, diễn biến giá cổ phiếu FPT trong giai đoạn gần đây cho thấy đặc điểm biến động đáng chú ý, phản ánh sự tương tác giữa các yếu tố nội tại doanh nghiệp và điều kiện kinh tế vĩ mô. Về phía doanh nghiệp, tăng trưởng mạnh của mảng xuất khẩu phần mềm, xu hướng chuyển đổi số toàn cầu và nhu cầu gia tăng đối với các giải pháp công nghệ mới (AI, điện toán đám mây) đã tạo nền tảng hỗ trợ kỳ vọng tăng trưởng dài hạn. Ở chiều ngược lại, cổ phiếu cũng chịu ảnh hưởng từ biến động tỷ giá, rủi ro suy giảm kinh tế toàn cầu và chính sách tiền tệ thắt chặt tại các nền kinh tế lớn, những yếu tố có thể tác động đến nhu cầu chi tiêu công nghệ của khách hàng quốc tế.

Sự đồng thời của các yếu tố thuận lợi và bất lợi khiến chuỗi giá cổ phiếu FPT thể hiện đặc trưng vừa có xu hướng tăng trưởng dài hạn, vừa xuất hiện các dao động ngắn hạn mang tính phi tuyến. Các giai đoạn điều chỉnh mạnh, đi kèm sự gia tăng đột biến về khối lượng giao dịch, cho thấy mức độ nhạy cảm của cổ phiếu trước thông tin lợi nhuận, kế hoạch kinh doanh và biến động kinh tế toàn cầu. Đặc điểm này đặt ra thách thức đáng kể cho các mô hình dự báo tuyến tính truyền thống, vốn giả định mối quan hệ ổn định và cấu trúc tuyến tính trong dữ liệu (Zhang, 2003).

Trong bối cảnh đó, việc nghiên cứu và dự báo giá cổ phiếu FPT không chỉ mang ý nghĩa thực tiễn đối với nhà đầu tư quan tâm đến nhóm ngành công nghệ tại Việt Nam, mà còn cung cấp một trường hợp nghiên cứu phù hợp để đánh giá hiệu quả của các mô hình lai kết hợp học sâu và học máy, chẳng hạn như LSTM và XGBoost. Cách tiếp cận lai được kỳ vọng có khả năng khai thác đồng thời cấu trúc phụ thuộc theo thời gian và

các quan hệ phi tuyến phức tạp trong dữ liệu tài chính, từ đó cải thiện độ chính xác dự báo trong điều kiện thị trường mới nổi có mức độ biến động cao (Hochreiter & Schmidhuber, 1997; Chen & Guestrin, 2016).

1.1.3. Khoảng trống phương pháp luận

Trong nhiều năm gần đây, các phương pháp học sâu (Deep Learning) đã trở thành hướng tiếp cận quan trọng trong dự báo chuỗi thời gian tài chính, đặc biệt trong bối cảnh dữ liệu thị trường có tính phi tuyến và biến động cao. Mạng nơ-ron hồi tiếp với bộ nhớ dài – ngắn hạn (LSTM) do Hochreiter và Schmidhuber (1997) đề xuất được đánh giá cao nhờ khả năng ghi nhớ phụ thuộc dài hạn và xử lý hiệu quả các chuỗi dữ liệu có cấu trúc động phức tạp. Thông qua cơ chế cổng điều tiết thông tin, LSTM có thể nắm bắt các quan hệ phi tuyến theo thời gian và hạn chế hiện tượng tiêu biến gradient thường gặp ở mạng hồi tiếp truyền thống. Vì vậy, LSTM đã được ứng dụng rộng rãi trong dự báo giá cổ phiếu và các biến tài chính. Tuy nhiên, mô hình này vẫn tồn tại một số hạn chế, bao gồm nguy cơ quá khớp khi dữ liệu nhiễu lớn, độ nhạy với cấu hình siêu tham số và yêu cầu khối lượng dữ liệu huấn luyện đủ lớn để đạt hiệu quả tối ưu.

Song song đó, các thuật toán học tổ hợp như XGBoost do Chen và Guestrin (2016) phát triển đã chứng minh hiệu quả vượt trội trong nhiều bài toán dự báo nhờ khả năng học các quan hệ phi tuyến phức tạp và tự động khai thác tương tác giữa các biến đầu vào. Cơ chế tăng cường gradient cùng chiến lược điều chuẩn (regularization) giúp XGBoost kiểm soát tốt độ phức tạp mô hình và cải thiện khả năng tổng quát hóa. Trong lĩnh vực tài chính, XGBoost thường được sử dụng để xử lý các tập đặc trưng kỹ thuật đa chiều. Tuy nhiên, khi áp dụng riêng lẻ cho chuỗi thời gian, mô hình này không được thiết kế chuyên biệt để khai thác cấu trúc phụ thuộc tuần tự dài hạn nếu không có bước xây dựng đặc trưng phù hợp.

Từ những phân tích trên, có thể nhận thấy khoảng trống phương pháp luận nằm ở việc thiếu một khuôn khổ tích hợp hiệu quả giữa khả năng học phụ thuộc theo thời gian của LSTM và năng lực khai thác cấu trúc phi tuyến của XGBoost. Do đó, nghiên cứu này đề xuất mô hình lai LSTM–XGBoost nhằm tận dụng ưu điểm bổ trợ của hai phương pháp. Cụ thể, LSTM được sử dụng để trích xuất đặc trưng động và nắm bắt xu hướng chính của chuỗi giá cổ phiếu, trong khi XGBoost đảm nhiệm vai trò tối ưu hóa dự báo thông qua việc học thêm các quan hệ phi tuyến còn lại trong dữ liệu.

Cách tiếp cận lai này được kỳ vọng sẽ cải thiện độ chính xác dự báo so với việc sử dụng từng mô hình đơn lẻ, đồng thời nâng cao khả năng thích ứng với đặc điểm biến động mạnh và cấu trúc phức tạp của dữ liệu tài chính tại các thị trường mới nổi. Trong

bối cảnh nghiên cứu dự báo giá cổ phiếu FPT, việc áp dụng mô hình LSTM–XGBoost không chỉ mang ý nghĩa thực nghiệm mà còn góp phần bổ sung bằng chứng cho xu hướng tích hợp học sâu và học máy trong phân tích chuỗi thời gian tài chính.

1.2. Mục tiêu nghiên cứu

Nghiên cứu này không chỉ dừng lại ở việc áp dụng các mô hình rời rạc, mà hướng tới việc xây dựng một quy trình (framework) dự báo hoàn chỉnh, khoa học và có thể tái lập dựa trên sự kết hợp giữa học sâu (Deep Learning) và học máy (Machine Learning). Các mục tiêu được chia làm hai cấp độ:

1.2.1 Mục tiêu tổng quát

Xây dựng, tối ưu hóa và kiểm định hiệu quả của mô hình lai ghép LSTM-XGBoost trong việc dự báo giá đóng cửa của cổ phiếu FPT, nhằm cung cấp một công cụ hỗ trợ ra quyết định đầu tư định lượng (Quantitative Trading) với độ tin cậy và độ chính xác cao.

1.2.2 Mục tiêu cụ thể

Để đạt được mục tiêu tổng quát, nghiên cứu sẽ thực hiện các nhiệm vụ cụ thể sau:

- Thu thập và tiền xử lý dữ liệu: Thu thập dữ liệu lịch sử giá cổ phiếu FPT và các chỉ số tài chính liên quan; thực hiện làm sạch, chuẩn hóa và trích xuất đặc trưng để xây dựng bộ dữ liệu huấn luyện khoa học.
- Xây dựng mô hình thành phần: Thiết kế mạng LSTM để trích xuất các phụ thuộc chuỗi thời gian dài hạn và mô hình XGBoost để tối ưu hóa khả năng dự báo trên dữ liệu cấu trúc.
- Tích hợp và huấn luyện mô hình lai: Xây dựng cơ chế kết hợp giữa LSTM và XGBoost nhằm tận dụng ưu điểm của cả hai phương pháp, giúp giảm thiểu sai số và tăng cường khả năng tổng quát hóa của mô hình.
- Đánh giá và kiểm định: Sử dụng các thước đo thống kê (như RMSE, MAE, MAPE) để đánh giá hiệu suất mô hình và thực hiện so sánh đối chứng với các mô hình đơn lẻ (chỉ LSTM hoặc chỉ XGBoost).
- Phân tích khả năng ứng dụng: Đánh giá tính thực tiễn của mô hình trong việc đưa ra các tín hiệu giao dịch cho mã cổ phiếu FPT trong môi trường thị trường thực tế.

1.3. Câu hỏi nghiên cứu

Một số câu hỏi nghiên cứu cụ thể được đặt ra như sau:

(1) Mô hình LSTM kết hợp với mô hình XGBoost được xây dựng và huấn luyện như thế nào để phù hợp với dữ liệu chuỗi thời gian của cổ phiếu FPT?

(2) Độ chính xác của mô hình LSTM kết hợp với mô hình XGBoost khi dự đoán giá cổ phiếu FPT được đánh giá thông qua các chỉ số sai số (MSE, MAE, MAPE, R^2) ra sao?

(3) Kết quả dự báo có phản ánh được xu hướng thực tế của thị trường và có đủ độ tin cậy để hỗ trợ quyết định đầu tư hay không?

1.4. Đối tượng và phạm vi nghiên cứu

1.4.1 Đối tượng nghiên cứu

Đối tượng vật lý (Thực thể nghiên cứu): Đối tượng vật lý trong nghiên cứu này là Công ty Cổ phần FPT (mã cổ phiếu: FPT). Đây là thực thể kinh tế đại diện, đóng vai trò là mẫu kiểm chứng cho hiệu năng của mô hình nhờ tính thanh khoản cao và sự minh bạch trong dữ liệu giao dịch trên sàn HOSE.

Đối tượng số liệu: nghiên cứu lựa chọn Giá đóng cửa (Price) của cổ phiếu FPT làm đối tượng số liệu cốt lõi để huấn luyện và kiểm chứng mô hình. Đây là mức giá quan trọng nhất trong ngày giao dịch, phản ánh sự đồng thuận cuối cùng giữa bên mua và bên bán, đồng thời là cơ sở tin cậy để xác định xu hướng kế tiếp. Chuỗi giá cổ phiếu của Công ty Cổ phần FPT (mã chứng khoán: FPT).

1.4.2 Phạm vi nghiên cứu

Để đảm bảo tính tập trung và hiệu quả trong việc xây dựng quy trình (framework) dự báo hoàn chỉnh, khoa học, nghiên cứu xác lập phạm vi giới hạn trên ba phương diện chính:

1.4.2.1. Phạm vi nội dung và công nghệ

Mô hình triển khai: Nghiên cứu chỉ tập trung vào việc thiết lập và tối ưu hóa mô hình lai ghép giữa mạng học sâu LSTM và thuật toán tăng cường độ dốc XGBoost.

Biến số nghiên cứu: Nội dung nghiên cứu tập trung phân tích và dự báo dựa trên chuỗi Giá đóng cửa (Price) của cổ phiếu. Các yếu tố ngoại sinh như tin tức chính trị, tâm lý thị trường (sentiment analysis) hoặc biến động kinh tế vĩ mô nằm ngoài phạm vi định lượng trực tiếp của mô hình này.

1.4.2.2 Phạm vi về đối tượng (Không gian)

Giai đoạn thu thập dữ liệu: Nghiên cứu sử dụng dữ liệu lịch sử trong khoảng thời gian từ ngày 03/02/2016 đến ngày 03/02/2026. Khoảng thời gian này đảm bảo đủ độ

dài để mô hình học được các đặc tính của thị trường trong các giai đoạn khác nhau như tăng trưởng, suy thoái và phục hồi .

1.5. Phương pháp nghiên cứu

Nghiên cứu sử dụng phương pháp định lượng kết hợp phân tích dữ liệu và học sâu. Quy trình thực hiện gồm các bước:

1. Thu thập dữ liệu: Thu thập dữ liệu lịch sử giá cổ phiếu FPT từ nguồn Investing.com.

2. Tiền xử lý dữ liệu: Làm sạch dữ liệu, chuyển đổi định dạng.

3. Phân tích khám phá dữ liệu (EDA): Phân tích xu hướng, biến động, thống kê mô tả của chuỗi giá.

4. Kiểm định tính dừng: Kiểm định tính dừng của chuỗi dữ liệu (ADF test) và thực hiện sai phân.

5. Xây dựng mô hình LSTM

    Chuẩn hóa dữ liệu (Min-Max Scaling).

    Tạo dữ liệu dạng chuỗi trượt (sliding window).

    Xây dựng kiến trúc mô hình LSTM với các lớp Dropout.

    Huấn luyện mô hình với tập huấn luyện (80%) và tập kiểm tra (20%).

6. Huấn luyện model XGBoost dựa trên phần dư để tạo kiến trúc mô hình lai

    Tính toán phần dư (Residuals).

    Huấn luyện bù sai số.

    Hợp nhất dự báo (Hybrid Integration).

7. Đánh giá mô hình:

    Dự báo trên tập kiểm tra cho mô hình LSTM.

    Tính toán các chỉ số đánh giá:R^2 MAE, RMSE, MAPE.

    Trực quan hóa kết quả dự báo so với giá trị thực tế.

8. Thảo luận và kết luận: So sánh hiệu quả của hai mô hình, chỉ ra ưu nhược điểm và đề xuất hướng ứng dụng.

1.6. Ý nghĩa khoa học và thực tiễn của đề tài

1.6.1. Ý nghĩa khoa học:

Đóng góp về phương pháp luận: Đề tài góp phần hệ thống hóa quy trình (framework) kết hợp giữa mô hình học sâu LSTM và thuật toán học máy XGBoost, tạo ra một cách tiếp cận mới trong việc xử lý dữ liệu tài chính có tính phi tuyến và biến động cao.

Tối ưu hóa khả năng dự báo: Nghiên cứu cung cấp các bằng chứng khoa học về việc tận dụng ưu điểm của mạng thần kinh trong việc ghi nhớ chuỗi thời gian kết hợp với khả năng hiệu chỉnh sai số của thuật toán tăng cường độ dốc.

Làm tài liệu tham khảo: Kết quả nghiên cứu đóng vai trò là nguồn tài liệu học thuật cho các nghiên cứu tiếp theo về mô hình lai ghép (hybrid models) áp dụng trong lĩnh vực kinh tế lượng và trí tuệ nhân tạo tại Việt Nam.

1.6.2. Ý nghĩa thực tiễn

Hỗ trợ ra quyết định đầu tư: Xây dựng thành công một công cụ dự báo giá đóng cửa cổ phiếu FPT với độ tin cậy cao, giúp các nhà đầu tư có thêm căn cứ định lượng để tối ưu hóa thời điểm giao dịch.

Quản trị rủi ro hiệu quả: Thông qua các chỉ số dự báo, người dùng có thể nhận diện sớm các xu hướng biến động bất thường, từ đó đưa ra các biện pháp phòng vệ rủi ro cho danh mục đầu tư.

Thúc đẩy giao dịch định lượng: Đề tài đặt nền tảng cho việc ứng dụng công nghệ AI vào thị trường chứng khoán, hỗ trợ chuyển đổi từ phương thức đầu tư cảm tính sang đầu tư dựa trên dữ liệu và mô hình khoa học.

Tính ứng dụng và linh hoạt: Quy trình dự báo hoàn chỉnh này có thể được điều chỉnh và tái lập để áp dụng cho các mã cổ phiếu khác hoặc các loại tài sản tài chính tương tự trên thị trường.

1.7. Kết cấu của đề tài

Ngoài phần mở đầu và kết luận, đề tài gồm ba chương:

- CHƯƠNG 1: GIỚI THIỆU
- CHƯƠNG 2: CƠ SỞ LÝ LUẬN VÀ TỔNG QUAN NGHIÊN CỨU.
- CHƯƠNG 3: THỰC NGHIỆM VÀ THẢO LUẬN.
- CHƯƠNG 4: KẾT LUẬN VÀ HÀM Ý

KẾT LUẬN CHƯƠNG 1

Chương 1 đã trình bày cơ sở lý luận và thực tiễn làm nền tảng cho đề tài "Xây dựng và ứng mô hình học máy để phân tích và dự đoán cổ phiếu FPT", bao gồm tổng quan thị trường chứng khoán Việt Nam, lý do lựa chọn đề tài, mục tiêu và câu hỏi nghiên cứu, phương pháp nghiên cứu cũng như ý nghĩa khoa học và thực tiễn của đề tài. Thông qua việc xác định rõ định hướng nghiên cứu và phạm vi triển khai đối với cổ phiếu của FPT, chương này đã làm rõ tính cần thiết và giá trị ứng dụng của mô hình LSTM trong dự báo tài chính. Đây là cơ sở quan trọng để triển khai các nội dung phân tích dữ liệu, xây dựng mô hình và đánh giá kết quả trong các chương tiếp theo.

CHƯƠNG 2: CƠ SỞ LÝ LUẬN VÀ TỔNG QUAN NGHIÊN CỨU

2.1. Tổng quan về thị trường chứng khoán Việt Nam

Kể từ khi chính thức vận hành phiên giao dịch đầu tiên vào tháng 7 năm 2000, thị trường chứng khoán Việt Nam đã từng bước khẳng định vai trò là kênh huy động vốn trung và dài hạn quan trọng của nền kinh tế, góp phần giảm dần sự phụ thuộc vào tín dụng ngân hàng và thúc đẩy quá trình phân bổ nguồn lực theo cơ chế thị trường (Nguyễn & Trần, 2020). Với cấu trúc vận hành trên Sở Giao dịch Chứng khoán Thành phố Hồ Chí Minh và Sở Giao dịch Chứng khoán Hà Nội, thị trường ngày càng hoàn thiện về thể chế và đa dạng hóa sản phẩm, bao gồm cổ phiếu, trái phiếu và các công cụ phái sinh, qua đó nâng cao tính thanh khoản và khả năng phòng ngừa rủi ro cho nhà đầu tư (Phạm, 2021). Giai đoạn 2015–2025 ghi nhận sự tăng trưởng mạnh mẽ cả về quy mô lẫn mức độ tham gia của nhà đầu tư; theo VnEconomy, tổng quy mô thị trường cổ phiếu và trái phiếu đã đạt khoảng 12,76 triệu tỷ đồng vào năm 2025, phản ánh sự mở rộng đáng kể của thị trường vốn trong cấu trúc tài chính quốc gia (VnEconomy, 2025). Đồng thời, sự gia tăng nhanh chóng của cơ sở nhà đầu tư với khoảng 10 triệu tài khoản giao dịch chứng khoán cho thấy mức độ phổ cập tài chính ngày càng sâu rộng (The Investor, 2025).

Dưới góc độ ổn định tài chính và phát triển bền vững, Ngân hàng Thế giới nhấn mạnh rằng việc phát triển thị trường vốn có ý nghĩa quan trọng trong việc nâng cao hiệu quả phân bổ nguồn lực và tăng cường khả năng chống chịu của hệ thống tài chính trước các cú sốc vĩ mô (Ngân hàng Thế giới, 2022). Tuy nhiên, Quỹ Tiền tệ Quốc tế cũng chỉ ra rằng thị trường vẫn đối mặt với những thách thức như chất lượng quản trị doanh nghiệp, mức độ minh bạch thông tin và rủi ro liên quan đến thị trường trái phiếu doanh nghiệp (Quỹ Tiền tệ Quốc tế, 2023). Nhìn chung, cùng với tiến trình hoàn thiện khung pháp lý và nâng cấp hạ tầng thị trường, thị trường chứng khoán Việt Nam đang chuyển dịch theo hướng chuyên nghiệp và hội nhập hơn, hướng tới mục tiêu nâng cao chất lượng thị trường và tiệm cận các chuẩn mực của thị trường mới nổi trong khu vực.

2.2. Lý thuyết nền tảng về dự báo chuỗi thời gian tài chính

2.2.1. Khái niệm và Đặc trưng của Chuỗi thời gian Tài chính

2.2.1.1. Khái niệm

Chuỗi thời gian tài chính là một tập hợp các quan sát về một biến số tài chính (như giá đóng cửa của cổ phiếu FPT) được thu thập và sắp xếp theo thứ tự thời gian với các khoảng cách đều nhau. Trong bài báo cáo này, đối tượng số liệu chính là Giá đóng

cửa (Price), đại diện cho một chuỗi dữ liệu mà giá trị tại thời điểm t luôn có sự tương quan nhất định với các giá trị trong quá khứ t-1, t-2,... .

2.2.1.2. Các đặc trưng cơ bản

Chuỗi thời gian tài chính sở hữu những đặc tính kỹ thuật phức tạp, làm tiền đề cho việc lựa chọn mô hình lai ghép:

Tính phi tuyến (Non-linearity): Giá cổ phiếu FPT không biến động theo các hàm số tuyến tính đơn giản mà chịu tác động bởi nhiều yếu tố phức tạp, đòi hỏi các mô hình có khả năng học sâu như LSTM để trích xuất đặc trưng.

Tính không dừng (Non-stationarity): Các đặc trưng thống kê của chuỗi giá như trung bình và phương sai thường thay đổi theo thời gian, gây khó khăn cho các mô hình truyền thống nhưng lại là lợi thế của các thuật toán học máy hiện đại.

Hiện tượng tự tương quan (Autocorrelation): Giá trị hiện tại của cổ phiếu có sự phụ thuộc chặt chẽ vào các giá trị trễ trước đó. Đây là đặc điểm mà mạng LSTM tập trung khai thác thông qua cơ chế bộ nhớ dài hạn.

Độ nhiễu cao (High Volatility & Noise): Dữ liệu tài chính luôn chứa đựng những biến động ngẫu nhiên do tâm lý thị trường. Việc kết hợp XGBoost giúp mô hình lọc nhiễu và tối ưu hóa sai số tốt hơn so với các phương pháp đơn lẻ.

Tính phân nhóm biến động (Volatility Clustering): Các giai đoạn biến động mạnh thường có xu hướng đi cùng nhau. Việc xây dựng một quy trình khoa học sẽ giúp nhận diện các "cụm" biến động này để đưa ra dự báo chính xác hơn.

2.2.2. Tính dừng (Stationarity) và Kiểm định Nghiệm đơn vị

2.2.2.1. Khái niệm Tính dừng

Trong phân tích chuỗi thời gian tài chính, một chuỗi số liệu được coi là dừng (stationary) nếu các đặc trưng thống kê của nó không thay đổi theo thời gian. Cụ thể, chuỗi dừng phải thỏa mãn ba điều kiện:

1. Giá trị trung bình (Mean): Hằng số, không phụ thuộc vào thời gian.
2. Phương sai (Variance): Hằng số, mức độ phân tán của dữ liệu ổn định qua các thời kỳ.
3. Hiệp phương sai (Autocovariance): Giữa hai thời điểm t và t+k chỉ phụ thuộc vào khoảng cách k, không phụ thuộc vào thời điểm t cụ thể.

Ý nghĩa thực tế: Hầu hết dữ liệu giá đóng cửa cổ phiếu (như FPT) là chuỗi không dừng vì chúng thường có xu hướng (trend) tăng hoặc giảm rõ rệt. Việc đưa trực tiếp

chuỗi không dừng vào mô hình học máy có thể dẫn đến hiện tượng "hồi quy giả mạo" (spurious regression), làm giảm độ tin cậy của dự báo.

2.2.2.2. Kiểm định Nghiệm đơn vị (Unit Root Test)

Để xác định một chuỗi thời gian là dừng hay không dừng một cách khoa học, nghiên cứu sử dụng kiểm định nghiệm đơn vị. Một chuỗi có nghiệm đơn vị là chuỗi không dừng.

Kiểm định Augmented Dickey-Fuller (ADF)

Đây là công cụ phổ biến nhất được sử dụng trong báo cáo này để kiểm tra tính dừng. Mô hình kiểm định ADF có dạng tổng quát:

$$\Delta Y_t = \alpha + \beta t + \gamma Y_{t-1} + \sum_{i=1}^{p} \delta_i \Delta Y_{t-i} + \varepsilon_t$$

Trong đó:

Y_t : Giá đóng cửa cổ phiếu FPT tại thời điểm t.

ΔY_t : Sai phân bậc 1 của Y_t.

γ : Hệ số để kiểm tra nghiệm đơn vị.

Quy tắc quyết định dựa trên giá trị p-value:

Giả thuyết H_0: $\gamma = 0$ (Chuỗi có nghiệm đơn vị → Chuỗi không dừng).

Giả thuyết H_0: $\gamma < 0$ (Chuỗi không có nghiệm đơn vị → Chuỗi dừng).

2.2.2.3. Tầm quan trọng đối với mô hình lai LSTM-XGBoost

Với LSTM: Việc sử dụng chuỗi dừng giúp mạng Neural tập trung học các quy luật biến động ngắn hạn (oscillation) thay vì bị "đánh lừa" bởi xu hướng dài hạn quá lớn, giúp mô hình hội tụ nhanh hơn.

Với XGBoost: Giúp thuật toán này tránh được các sai số cực đại khi gặp phải các mức giá nằm ngoài khoảng dữ liệu đã huấn luyện (out-of-range).

2.2.3. Giả thuyết Bước đi ngẫu nhiên RWH (Random Walk Hypothesis)

2.2.3.1. Nội dung giả thuyết

Giả thuyết Bước đi ngẫu nhiên (RWH) cho rằng các thay đổi trong giá cổ phiếu là độc lập và có sự phân phối xác suất đồng nhất. Theo đó, biến động giá trong quá khứ không thể được sử dụng để dự báo biến động giá trong tương lai một cách chính xác. Công thức tổng quát của bước đi ngẫu nhiên được thể hiện qua phương trình:

$$P_t = P_{t-1} + \varepsilon_t$$

ε_t : Thành phần nhiễu trắng (white noise), đại diện cho các thông tin mới ngẫu nhiên xuất hiện trên thị trường

2.2.3.2. Mối quan hệ với Hiệu quả thị trường (EMH)

RWH có mối liên hệ chặt chẽ với Giả thuyết thị trường hiệu quả (Efficient Market Hypothesis). Nếu thị trường đạt mức độ hiệu quả dạng yếu, mọi thông tin về giá lịch sử đã được phản ánh hết vào giá hiện tại, khiến việc tìm kiếm lợi nhuận dựa trên phân tích kỹ thuật hay các mô hình học máy trở nên vô hiệu.

2.2.3.3 Ý nghĩa đối với mô hình dự báo LSTM - XGBoost

Trong bài báo cáo này, RWH đóng vai trò là giả thuyết đối chứng (Benchmark):

Thách thức đối với mô hình: Nếu giá cổ phiếu FPT tuân theo bước đi ngẫu nhiên hoàn hảo, thì sai số dự báo của mô hình LSTM-XGBoost sẽ không tốt hơn so với mô hình ngây thơ (Naive model - dự báo giá ngày mai bằng giá ngày hôm nay).

Cơ sở tồn tại của mô hình: Tuy nhiên, nhiều nghiên cứu thực nghiệm đã chỉ ra rằng thị trường tài chính thường có xu hướng và tồn tại các cấu trúc phi tuyến phức tạp do tâm lý nhà đầu tư. Việc sử dụng LSTM để bắt lấy sự phụ thuộc thời gian và XGBoost để xử lý các đặc trưng phi tuyến chính là nỗ lực nhằm chứng minh rằng giá cổ phiếu FPT không hoàn toàn là một bước đi ngẫu nhiên.

2.3. Mô hình LSTM (Long Short - Term Memory)

LSTM (Long Short-Term Memory) là một biến thể của mạng nơ-ron hồi tiếp (RNN) được thiết kế nhằm giải quyết hạn chế về khả năng ghi nhớ dài hạn của các mô hình truyền thống. LSTM được xem là một trong những mô hình học sâu hiệu quả nhất trong dự báo chuỗi thời gian, đặc biệt trong các lĩnh vực có dữ liệu biến động phức tạp như tài chính, chứng khoán và kinh tế.

Ưu điểm nổi bật của LSTM là khả năng ghi nhớ các mối quan hệ dài hạn trong dữ liệu quá khứ. Nhờ kiến trúc đặc biệt gồm các cổng điều khiển như cổng quên, cổng đầu vào và cổng đầu ra, mô hình có thể chọn lọc thông tin quan trọng cần giữ lại và loại bỏ các yếu tố nhiễu trong quá trình huấn luyện. Điều này giúp LSTM xử lý đồng thời cả thông tin ngắn hạn và dài hạn của chuỗi dữ liệu.

So với mạng RNN truyền thống, LSTM khắc phục hiệu quả hiện tượng mất gradient - nguyên nhân khiến mô hình không thể học được các quan hệ xa trong chuỗi thời gian dài. Nhờ đó, LSTM đặc biệt phù hợp trong bài toán dự báo giá cổ phiếu, nơi các xu hướng thị trường có thể chịu ảnh hưởng từ các sự kiện xảy ra nhiều tháng hoặc nhiều năm trước.

2.3.1. Cấu trúc mô hình

Một khối LSTM được thiết kế nhằm xử lý dữ liệu có tính phụ thuộc theo thời gian thông qua hệ thống bộ nhớ và các cổng điều khiển. Cấu trúc cơ bản gồm ba cổng chính: cổng quên, cổng đầu vào và cổng đầu ra, hoạt động dựa trên trạng thái bộ nhớ (Cell State).

Cổng quên (Forget Gate) quyết định mức độ giữ lại hoặc loại bỏ thông tin từ trạng thái bộ nhớ trước đó. Cổng này sử dụng hàm sigmoid để tạo ra các giá trị từ 0 đến 1, biểu thị mức độ quan trọng của từng thông tin. Những giá trị gần 0 sẽ bị loại bỏ, trong khi giá trị gần 1 sẽ được giữ lại.

Cổng đầu vào (Input Gate) có nhiệm vụ cập nhật thông tin mới vào bộ nhớ. Quá trình này gồm hai bước: sử dụng hàm sigmoid để xác định phần thông tin cần cập nhật và hàm tanh để tạo vector dữ liệu mới, sau đó kết hợp để điều chỉnh trạng thái bộ nhớ.

Cổng đầu ra (Output Gate) xác định thông tin nào từ bộ nhớ sẽ được truyền sang bước tiếp theo và tạo ra trạng thái ẩn của mô hình. Nhờ cơ chế này, LSTM tập trung vào các đặc trưng quan trọng và giảm ảnh hưởng của nhiễu dữ liệu.

Trạng thái bộ nhớ (Cell State) đóng vai trò trung tâm, giúp duy trì dòng thông tin xuyên suốt chuỗi thời gian. Bộ nhớ được cập nhật bằng cách kết hợp thông tin cũ được giữ lại từ cổng quên và thông tin mới từ cổng đầu vào. Điều này cho phép LSTM học được các mối quan hệ dài hạn mà không bị mất thông tin qua nhiều bước thời gian.

Sau khi trạng thái bộ nhớ được cập nhật, cổng đầu ra (output gate) sẽ tạo ra trạng thái ẩn hth_tht. Trạng thái này vừa đóng vai trò là đầu ra của mô hình tại thời điểm hiện tại, vừa được truyền sang bước thời gian tiếp theo làm đầu vào cho quá trình tính toán tiếp theo. Nhờ cơ chế này, các thông tin quan trọng được duy trì và lan truyền liên tục dọc theo chuỗi dữ liệu, giúp mô hình nắm bắt được các phụ thuộc dài hạn và nâng cao hiệu quả trong nhiệm vụ dự báo.

2.3.2. Giả định của mô hình

Khi áp dụng LSTM vào dự báo giá cổ phiếu FPT, mô hình dựa trên một số giả định cơ bản:

- Giá cổ phiếu có tính phụ thuộc theo thời gian, tức là giá hiện tại chịu ảnh hưởng từ các mức giá trong quá khứ.
- Các mẫu hình và xu hướng đã xuất hiện trong lịch sử có khả năng lặp lại trong tương lai.

- Dữ liệu đầu vào đủ lớn và có chất lượng tốt để mô hình học được các quy luật ẩn.
- Dữ liệu cần được tiền xử lý và chuẩn hóa phù hợp nhằm đảm bảo quá trình huấn luyện ổn định.

2.3.3. Quy trình xây dựng mô hình LSTM trong dự báo giá cổ phiếu

Quy trình xây dựng mô hình LSTM cho bài toán dự báo cổ phiếu FPT gồm các bước chính:

Trước tiên, dữ liệu lịch sử được thu thập bao gồm giá mở cửa, giá đóng cửa, giá cao nhất, giá thấp nhất và khối lượng giao dịch. Ngoài ra, các chỉ báo kỹ thuật có thể được bổ sung để tăng lượng thông tin cho mô hình.

Tiếp theo, dữ liệu được tiền xử lý bằng cách xử lý giá trị thiếu và chuẩn hóa về cùng thang đo nhằm giúp quá trình học diễn ra nhanh và ổn định hơn. Dữ liệu sau đó được chuyển thành dạng chuỗi trượt (sliding window), trong đó các quan sát quá khứ được sử dụng để dự đoán giá trị tương lai.

Sau đó, dữ liệu được chia thành tập huấn luyện và tập kiểm tra theo thứ tự thời gian nhằm đảm bảo tính thực tế của bài toán dự báo. Mô hình LSTM được thiết kế với số lớp và số nút phù hợp, kết hợp các kỹ thuật chống quá khớp như Dropout hoặc Early Stopping.

Cuối cùng, mô hình được đánh giá thông qua các chỉ tiêu sai số và so sánh trực quan giữa giá dự báo và giá thực tế để đánh giá hiệu quả dự báo.

2.3.4. Ưu điểm và hạn chế của mô hình LSTM

Mô hình LSTM nổi bật trong việc xử lý dữ liệu chuỗi thời gian nhờ cơ chế lưu giữ và cập nhật thông tin trong dài hạn. Khi áp dụng vào dự báo giá cổ phiếu, đặc điểm này cho phép mô hình không chỉ phản ánh các dao động ngắn hạn mà còn nhận diện được xu hướng vận động dài hạn của thị trường. So với nhiều phương pháp truyền thống, LSTM không đòi hỏi chuỗi dữ liệu phải thỏa mãn tính dừng, vì vậy có thể sử dụng trực tiếp cho dữ liệu tài chính vốn thường xuyên biến động và thiếu ổn định.

Ngoài ra, LSTM có khả năng nắm bắt các mối quan hệ phi tuyến phức tạp giữa các biến đầu vào, điều mà các mô hình hồi quy tuyến tính khó thực hiện hiệu quả. Khi so sánh với RNN thông thường, LSTM cho hiệu suất dự báo ổn định hơn đối với các chuỗi dữ liệu dài, đồng thời giảm thiểu tình trạng mất mát thông tin trong quá trình huấn

luyện. Nhờ những ưu thế này, LSTM được xem là một trong những mô hình học sâu phù hợp cho bài toán dự báo giá cổ phiếu.

Tuy vậy, LSTM vẫn tồn tại những hạn chế nhất định. Trước hết, mô hình cần một khối lượng dữ liệu đủ lớn và đảm bảo chất lượng để có thể học được các quy luật tiềm ẩn trong chuỗi thời gian. Nếu dữ liệu quá ngắn hoặc chứa nhiều nhiễu, độ chính xác của dự báo có thể bị ảnh hưởng.

Bên cạnh đó, quá trình huấn luyện LSTM thường đòi hỏi nhiều thời gian và tài nguyên tính toán hơn so với các mô hình truyền thống do cấu trúc phức tạp và số lượng tham số lớn. Một điểm hạn chế quan trọng khác là tính khó diễn giải của mô hình: cơ chế hoạt động phức tạp khiến việc xác định mức độ tác động của từng biến đầu vào đến kết quả dự báo trở nên không rõ ràng. Điều này có thể gây khó khăn trong lĩnh vực tài chính, nơi các nhà đầu tư và nhà quản lý thường yêu cầu sự minh bạch trong cơ sở ra quyết định.

2.4. Mô hình XGBoost (Extreme Gradient Boosting)

2.4.1. Giới thiệu thuật toán

XGBoost là một thuật toán học máy thuộc nhóm phương pháp học kết hợp (Ensemble Learning), cụ thể dựa trên kỹ thuật tăng cường độ dốc với cây quyết định (Gradient Boosting Decision Trees – GBDT), do Chen và Guestrin công bố năm 2016. Thuật toán này ra đời nhằm cải thiện hiệu suất tính toán cũng như khả năng mở rộng mà các mô hình boosting truyền thống còn hạn chế.

Thay vì sử dụng một cây quyết định riêng lẻ, XGBoost phát triển một tập hợp nhiều cây theo cách xây dựng tuần tự. Trong quá trình huấn luyện, mỗi cây mới được thêm vào có nhiệm vụ điều chỉnh các phần sai số (residuals) mà các cây trước đó chưa xử lý tốt. Nhờ cơ chế liên tục tối ưu sai số này, mô hình từng bước nâng cao chất lượng dự báo, tập trung nhiều hơn vào những quan sát khó, từ đó cải thiện độ chính xác chung của toàn bộ hệ thống

2.4.2. Cơ chế hoạt động và Hàm mục tiêu

Mục tiêu cốt lõi của XGBoost là tối ưu một hàm mục tiêu (objective function) gồm hai phần: thành phần đo lường sai số dự báo và thành phần điều chuẩn nhằm kiểm soát mức độ phức tạp của mô hình. Hàm mục tiêu tổng quát có dạng:

$$L(\phi) = \sum_i l(\hat{y}_i, y_i) + \sum_k \Omega(f_k)$$

Trong đó, $l(\hat{y}_i, y_i)$ là hàm mất mát, thường được sử dụng dưới dạng sai số bình phương trung bình (Mean Squared Error – MSE) trong các bài toán hồi quy, nhằm đánh giá mức chênh lệch giữa giá trị dự báo $\hat{y}_i$ và giá trị thực tế y_i.

Thành phần $\Omega(f_k)$ là hàm điều chuẩn áp dụng cho từng cây quyết định f_k trong mô hình, có vai trò hạn chế độ phức tạp của cây. Biểu thức điều chuẩn thường được viết như sau:

$$\Omega(f_k) = \gamma T + \tfrac{1}{2}\lambda\|w\|^2$$

Ở đây, T là số lượng nút lá của cây, w là vector trọng số tương ứng với các lá, còn γ và λ là các siêu tham số điều chỉnh mức độ phạt. Nhờ cơ chế này, mô hình tránh được việc phát triển cấu trúc quá phức tạp, qua đó giảm nguy cơ quá khớp (overfitting), đặc biệt trong bối cảnh dữ liệu tài chính thường chứa nhiều nhiễu.

Để tìm nghiệm tối ưu cho hàm mục tiêu, XGBoost áp dụng khai triển Taylor bậc hai đối với hàm mất mát, qua đó tận dụng đồng thời thông tin từ đạo hàm bậc nhất (gradient) và bậc hai (Hessian). Cách tiếp cận này giúp quá trình tối ưu diễn ra nhanh và ổn định hơn so với các phương pháp Gradient Boosting truyền thống, đồng thời cải thiện hiệu quả dự báo trong những bài toán có cấu trúc phức tạp (Chen & Guestrin, 2016).

2.5. Mô hình lai (Hybrid Model) và lý thuyết phân rã sai số

2.5.1. Cơ sở lý thuyết của Phương pháp Lai ghép

Phương pháp lai ghép (Hybrid Approach) dựa trên triết lý "Chia để trị" và Phân rã dữ liệu. Cụ thể:

Lý thuyết phân rã: Một chuỗi thời gian giá đóng cửa cổ phiếu FPT (Yt) có thể được coi là sự kết hợp của hai thành phần: thành phần có cấu trúc/xu hướng (Lt) và thành phần sai số/phi tuyến (Nt):

$$Yt = Lt + Nt$$

Cơ chế hoạt động:

LSTM (Long Short-Term Memory): Được thiết kế để xử lý thành phần Lt. Với các cổng nhớ (Gate), LSTM trích xuất các phụ thuộc dài hạn và xu hướng chủ đạo của giá Price.

XGBoost (Extreme Gradient Boosting): Được dùng để xử lý thành phần Nt(Residuals - Sai số). Sau khi LSTM đưa ra dự báo sơ bộ, các phần sai số mà LSTM chưa học hết sẽ được XGBoost huấn luyện lại để tinh chỉnh.

Mục tiêu: Sự kết hợp này giúp giảm thiểu tổng sai số dự báo, đồng thời tận dụng được thế mạnh của Deep Learning (trích xuất đặc trưng tự động) và Machine Learning truyền thống (tối ưu hóa Gradient mạnh mẽ).

2.5.2. Tổng quan các nghiên cứu thực nghiệm

Việc xây dựng quy trình này kế thừa từ nhiều công trình nghiên cứu uy tín:

Nhóm nghiên cứu về mô hình học máy truyền thống và Boosting: Nghiên cứu của Chen & Guestrin (2016) về thuật toán XGBoost đã tạo ra một bước ngoặt trong việc xử lý dữ liệu bảng (tabular data). Các thực nghiệm trên thị trường chứng khoán cho thấy XGBoost có khả năng xử lý tốt các dữ liệu bị nhiễu và ngăn chặn quá khớp (overfitting) thông qua cơ chế kiểm soát độ phức tạp của cây. Tuy nhiên, nhóm nghiên cứu này cũng chỉ ra hạn chế của XGBoost là khó nắm bắt được tính phụ thuộc thời gian (temporal dependencies) nếu không có bước tiền xử lý đặc trưng kỹ lưỡng.

Nhóm nghiên cứu về mạng học sâu (Deep Learning): Fischer & Krauss (2018) đã thực hiện một nghiên cứu quy mô lớn trên dữ liệu S&P 500 và chứng minh rằng mạng LSTM vượt trội hơn hẳn so với các mô hình hồi quy truyền thống. LSTM có khả năng trích xuất các quy luật từ dữ liệu quá khứ nhờ cơ chế các cổng (gates), giúp ghi nhớ các "trí nhớ dài hạn" của thị trường. Tại Việt Nam, các nghiên cứu gần đây áp dụng LSTM cho các mã cổ phiếu vốn hóa lớn (Blue-chips) cũng cho thấy độ chính xác cao trong việc dự báo xu hướng giá đóng cửa.

Nhóm nghiên cứu về mô hình lai ghép (Hybrid Approach): Xu hướng kết hợp các thế mạnh của nhiều thuật toán đang trở thành tâm điểm của các nghiên cứu mới nhất. Nghiên cứu của Chen, Wei & Xu (2020) đã thử nghiệm mô hình kết hợp LSTM và XGBoost, trong đó LSTM đóng vai trò trích xuất đặc trưng chuỗi thời gian, còn XGBoost đóng vai trò là bộ hồi quy cuối cùng. Kết quả thực nghiệm cho thấy sai số bình phương trung bình (RMSE) của mô hình lai thấp hơn đáng kể so với việc sử dụng LSTM hay XGBoost đơn lẻ.

2.5.3. Khoảng trống nghiên cứu (Research Gap)

Mặc dù các mô hình lai đã có những thành tựu nhất định, nghiên cứu này nhận thấy vẫn tồn tại những khoảng trống cần lấp đầy:

Tính đặc thù của mã cổ phiếu công nghệ: Hầu hết các nghiên cứu lai ghép tại Việt Nam áp dụng cho nhóm ngành ngân hàng hoặc bất động sản. Mã FPT – một cổ phiếu công nghệ với đặc thù tăng trưởng ổn định nhưng nhạy cảm với thông tin kỹ thuật – chưa có một quy trình dự báo lai ghép chuyên biệt nào được công bố rộng rãi.

Sự tích hợp dữ liệu chưa tối ưu: Nhiều nghiên cứu chỉ dùng giá Price làm đầu vào duy nhất. Đề tài này giải quyết khoảng trống đó bằng cách tích hợp thêm các chỉ báo kỹ thuật phối hợp cùng mô hình lai để tăng khả năng nhận diện điểm đảo chiều.

Tính hệ thống của Framework: Hiện nay thiếu một quy trình (framework) hoàn chỉnh, khoa học và có khả năng tái lập giúp nhà đầu tư cá nhân có thể tự cài đặt và sử dụng mô hình lai này một cách dễ dàng.

2.6. Các chỉ tiêu đánh giá mô hình dự báo

Mức độ phù hợp của mô hình hồi quy so với dữ liệu thực tế (R^2)

$$R^2 = 1 - \frac{SS_{res}}{Ss_{tot}}$$

Sai số tuyệt đối trung bình (MAE):

$$MAE = \frac{\sum_{i=1}^{n} |yi - \widehat{yi}|}{n}$$

Sai số bình phương trung bình (MSE):

$$MSE = \frac{\sum_{i=1}^{n} (yi - \widehat{yi})^2}{n}$$

Căn bậc hai sai số bình phương trung bình (RMSE):

$$RMSE = \sqrt{\frac{\sum_{i=1}^{n} (yi - \widehat{yi})^2}{n}}$$

Sai số phần trăm tuyệt đối trung bình (MAPE):

$$MAPE = \frac{1}{n} \sum_{k=1}^{n} \left| \frac{(yi - \widehat{yi})^2}{yi} \right|$$

Các chỉ tiêu này giúp đánh giá mức độ sai lệch giữa giá dự báo và giá thực tế, từ đó lựa chọn mô hình dự báo phù hợp nhất.

KẾT LUẬN CHƯƠNG 2

Tổng kết Chương 2, nghiên cứu đã hệ thống hóa toàn diện cơ sở lý luận về thị trường chứng khoán Việt Nam và các đặc trưng kỹ thuật của chuỗi thời gian tài chính như tính phi tuyến, không dừng và độ nhiễu cao. Qua việc đối chiếu với Giả thuyết Bước đi ngẫu nhiên (RWH), đề tài khẳng định sự tồn tại của các cấu trúc dữ liệu phức tạp mà các mô hình học máy có thể khai thác thay vì chỉ dựa vào các mô hình truyền thống.

Việc lựa chọn mô hình lai dựa trên cơ chế phân rã sai số là bước đi chiến lược: mạng LSTM chịu trách nhiệm trích xuất xu hướng và các phụ thuộc dài hạn , trong khi XGBoost tập trung xử lý phần dư (residuals) để tinh chỉnh các biến động phi tuyến và lọc nhiễu. Tổng quan các nghiên cứu thực nghiệm đã chứng minh tính ưu việt của phương pháp này trong việc tối ưu hóa độ chính xác dự báo so với các mô hình đơn lẻ. Đây chính là nền tảng lý thuyết vững chắc để xây dựng một quy trình dự báo khoa học, có tính tái lập, nhằm lấp đầy khoảng trống nghiên cứu chuyên biệt cho mã cổ phiếu FPT tại thị trường Việt Nam.

CHƯƠNG 3: THỰC NGHIỆM VÀ THẢO LUẬN

3.1 Nguồn dữ liệu

Dữ liệu được sử dụng trong đề tài là dữ liệu lịch sử giá cổ phiếu FPT, được thu thập trong giai đoạn từ tháng 2/2016 đến ngày 3/2/2026, được thu thập từ cổng thông tin tài chính toàn diện cho nhà đầu tư - Investing.com. Cổ phiếu FPT thuộc FPT Corporation – một trong những doanh nghiệp công nghệ thông tin hàng đầu tại Việt Nam và được niêm yết trên Sở Giao dịch Chứng khoán Thành phố Hồ Chí Minh (HOSE).Bộ dữ liệu phản ánh biến động giá cổ phiếu FPT theo tần suất ngày trong khoảng thời gian được lưu trữ trong tệp dữ liệu.

Bộ dữ liệu cho phép dữ liệu dễ dàng tích hợp với các thư viện xử lý dữ liệu và mô hình LSTM trong môi trường Python. Việc sử dụng dữ liệu lịch sử thực tế của cổ phiếu FPT giúp đảm bảo tính liên tục theo thời gian, độ tin cậy cao và hạn chế sai lệch dữ liệu, từ đó nâng cao chất lượng và tính khách quan của kết quả dự báo trong nghiên cứu.

3.2 Mô tả dữ liệu

Bộ dữ liệu lịch sử giá cổ phiếu FPT bao gồm các trường thông tin phản ánh toàn diện diễn biến bao gồm các trường dữ liệu sau:

Ngày giao dịch (Date)

Giá đóng cửa của cổ phiếu FPT (Price)

Mở(Open): Giá cổ phiếu tại thời điểm bắt đầu phiên giao dịch trong ngày.

Cao/Thấp: Mức giá cao/thấp nhất mà cổ phiếu FPT đạt được trong suốt ngày giao dịch.

KL: Tổng khối lượng cổ phiếu FPT được giao dịch trong ngày

Tỷ lệ phần trăm thay đổi giá cổ phiếu FPT so với ngày giao dịch liền trước(Change),

Trong phạm vi nghiên cứu này, trường Price (giá đóng cửa) được lựa chọn làm biến chính để thực hiện dự báo bằng mô hình LSTM. Việc sử dụng giá đóng cửa làm biến mục tiêu là phù hợp với thông lệ trong các nghiên cứu dự báo tài chính, bởi chỉ số này tổng hợp đầy đủ tác động của các yếu tố thị trường trong suốt một phiên giao dịch.

Chuỗi dữ liệu có tính liên tục theo thời gian, không xuất hiện các giá trị thiếu nghiêm trọng và đã được kiểm tra sơ bộ về tính hợp lệ trước khi đưa vào giai đoạn tiền xử lý. Đặc điểm này giúp dữ liệu phù hợp để xây dựng mô hình dự báo chuỗi thời gian

dựa trên mạng nơ-ron hồi tiếp LSTM, cho phép mô hình học được các xu hướng và mẫu biến động giá của cổ phiếu FPT trong ngắn hạn và trung hạn.

3.3. Tiền xử lý dữ liệu

Trong thực tiễn, dữ liệu tài chính thường không hình thành một chuỗi liên tục do bị gián đoạn bởi các ngày nghỉ cuối tuần và các kỳ nghỉ lễ. Trong khi đó, phần lớn các mô hình chuỗi thời gian đòi hỏi dữ liệu phải được tổ chức liên tục theo trục thời gian nhằm đảm bảo việc tính toán các độ trễ (lag) và các đặc trưng động học được chính xác. Vì vậy, trước khi tiến hành phân tích, dữ liệu cần được tiền xử lý để đảm bảo tính liên tục theo thời gian (time continuity).

Cụ thể, quy trình xử lý được thực hiện qua hai bước chính. Thứ nhất, dữ liệu được tái lấy mẫu (resampling) về tần suất "ngày dương lịch" (Daily – ký hiệu "D") nhằm chuẩn hóa chuỗi thời gian theo từng ngày liên tiếp. Thứ hai, các giá trị khuyết phát sinh trong quá trình tái lấy mẫu được xử lý bằng phương pháp nội suy tuyến tính (linear interpolation).

Phương pháp nội suy tuyến tính giả định rằng sự thay đổi giá giữa hai thời điểm quan sát gần nhất diễn ra một cách tuyến tính, từ đó ước lượng giá trị tại các ngày không có giao dịch. Cách tiếp cận này giúp duy trì tính liên tục của chuỗi dữ liệu, đồng thời tránh việc giữ nguyên mức giá như phương pháp điền trước (forward fill), qua đó phản ánh mượt hơn quỹ đạo biến động giá trong giai đoạn không có giao dịch.

Sau quá trình làm sạch và chuẩn hóa, bộ dữ liệu thu được gồm 3.653 quan sát liên tục theo ngày dương lịch và không còn giá trị thiếu (null), tạo nền tảng phù hợp cho các bước phân tích và xây dựng mô hình tiếp theo

3.4. Mô tả và thống kê dữ liệu

Bộ dữ liệu nghiên cứu gồm 3.653 quan sát, phản ánh diễn biến của đối tượng nghiên cứu trong toàn bộ giai đoạn khảo sát. Quy mô dữ liệu ở mức tương đối lớn, đủ để phản ánh xu hướng và biến động theo thời gian, đồng thời đảm bảo độ tin cậy cho các phân tích thống kê mô tả và mô hình hóa tiếp theo.

Trong phạm vi nghiên cứu này, chỉ hai biến Date và Price được lựa chọn để phục vụ cho phân tích. Biến Date đại diện cho yếu tố thời gian, cho phép xây dựng và phân tích chuỗi dữ liệu theo trình tự thời gian, trong khi biến Price phản ánh giá đóng cửa – chỉ tiêu quan trọng và thường được sử dụng trong các nghiên cứu phân tích xu hướng và dự báo. Việc tập trung vào hai biến cốt lõi giúp mô hình hóa dữ liệu theo hướng đơn

giản, trực quan và phù hợp với mục tiêu nghiên cứu, đồng thời hạn chế nhiễu từ các biến không cần thiết.

Hình 3.4. Biểu đồ giá cổ phiếu FPT

Biểu đồ giá đóng cửa cổ phiếu FPT trong giai đoạn 2016–2026 cho thấy chuỗi dữ liệu có xu hướng tăng trong dài hạn, đồng thời tồn tại mức độ biến động đáng kể theo thời gian. Giá cổ phiếu tăng từ khoảng 40.000–45.000 đồng vào đầu giai đoạn lên khoảng 130.000–140.000 đồng vào cuối kỳ, phản ánh sự thay đổi rõ rệt về mặt quy mô giá trong suốt thời gian nghiên cứu.

Trong giai đoạn 2016–2018, giá cổ phiếu tương đối ổn định với biên độ dao động hẹp. Từ năm 2018 trở đi, mức độ biến động gia tăng, thể hiện qua các giai đoạn tăng mạnh xen kẽ với các đợt điều chỉnh đáng kể. Đặc biệt, giai đoạn 2021–2024 ghi nhận sự dao động mạnh với mức giá đạt đỉnh cục bộ gần 140.000 đồng, sau đó điều chỉnh giảm trước khi phục hồi trở lại trong các năm cuối kỳ.

Nhìn chung, chuỗi giá đóng cửa cổ phiếu FPT mang đặc trưng của dữ liệu chuỗi thời gian tài chính với xu hướng tăng dài hạn, tính mùa vụ không rõ ràng và mức độ biến động cao. Những đặc điểm này là cơ sở quan trọng cho việc lựa chọn các phương pháp phân tích và mô hình hóa phù hợp trong các phần tiếp theo của nghiên cứu.

Tóm lại, bộ dữ liệu được sử dụng trong nghiên cứu có quy mô và cấu trúc phù hợp, với số lượng quan sát tương đối lớn và hệ thống biến ở mức vừa phải, cho phép phản ánh đầy đủ diễn biến của giá cổ phiếu FPT trong giai đoạn nghiên cứu. Dữ liệu có tính toàn vẹn cao khi không tồn tại giá trị khuyết, đồng thời thể hiện rõ đặc trưng của chuỗi thời gian tài chính với xu hướng tăng dài hạn và mức độ biến động đáng kể.

Các kết quả thống kê và trực quan hóa cho thấy giá đóng cửa phân bố trên một khoảng rộng, không đối xứng và tập trung ở một số mức giá nhất định, phản ánh sự dao động của thị trường theo thời gian. Bên cạnh đó, việc các biến ban đầu được lưu trữ dưới dạng ký tự cho thấy sự cần thiết của bước tiền xử lý dữ liệu nhằm chuyển đổi định dạng và chuẩn hóa dữ liệu trước khi áp dụng các phương pháp phân tích định lượng. Những đặc điểm được nhận diện trong phần này đóng vai trò nền tảng cho việc lựa chọn phương pháp phân tích và xây dựng mô hình phù hợp ở các phần tiếp theo của nghiên cứu.

3.4.1 Phân tích dư liệu chuỗi thời gian của dữ liệu cổ phiếu FPT

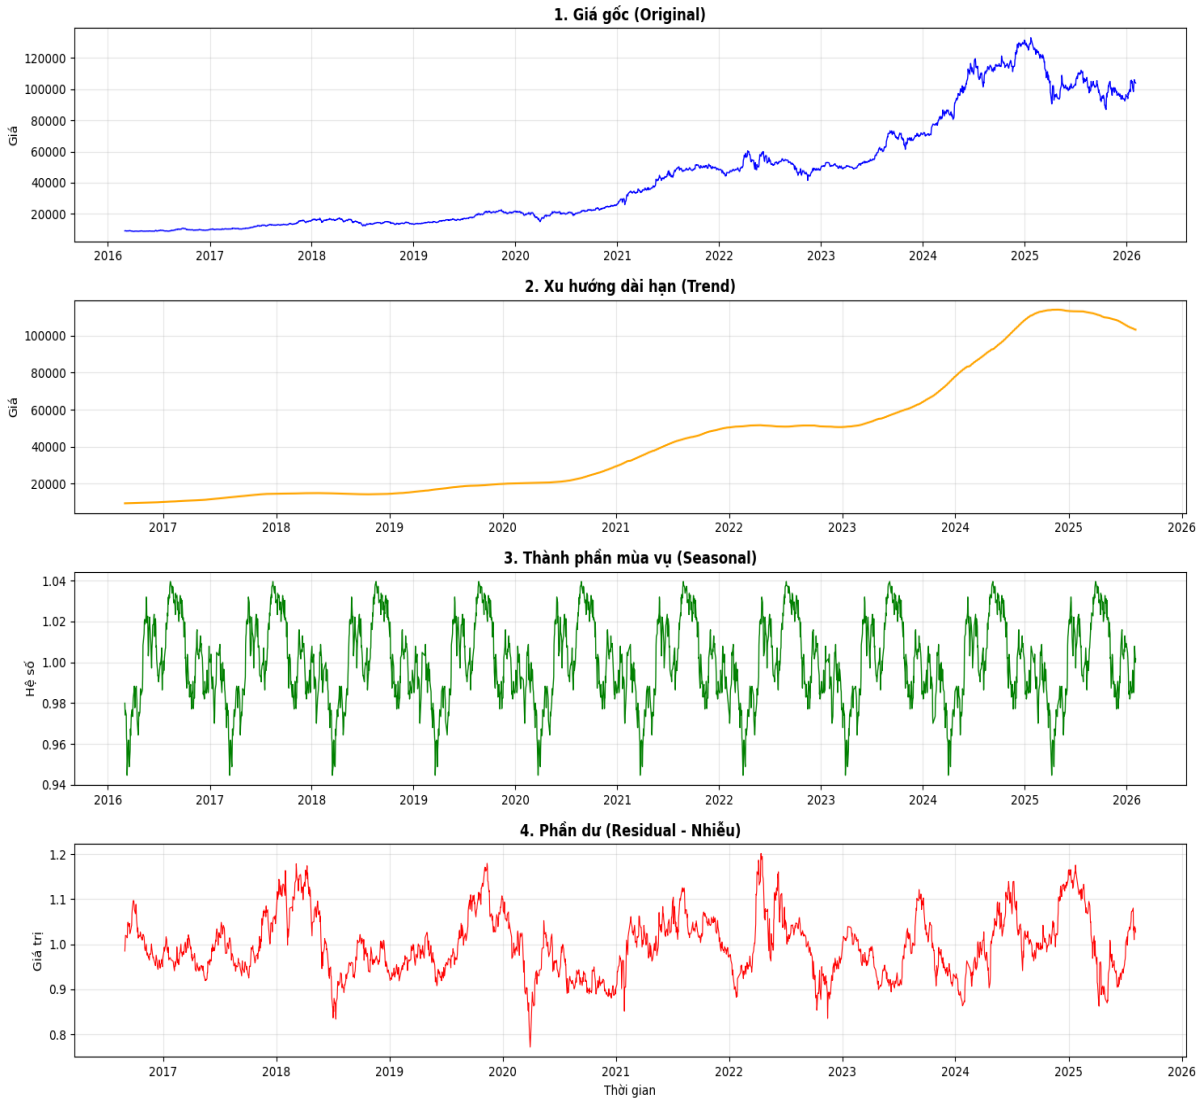

Hình 3.4.1. Phân tích dư liệu chuỗi thời gian của dữ liệu cổ phiếu FPT

Kết quả phân tích cho thấy phương sai giá gốc của cổ phiếu FPT đạt 1.247.719.994,47, một con số phản ánh mức độ biến động lớn của giá cổ phiếu trong giai đoạn nghiên cứu.

Về cấu trúc biến động, thành phần xu hướng (Trend) chiếm tới 87,1% tổng phương sai giá, cho thấy biến động giá FPT chủ yếu đến từ xu hướng dài hạn của thị trường và nội tại doanh nghiệp, thay vì các yếu tố mùa vụ hay nhiễu ngắn hạn. Điều này phản ánh đúng bản chất của cổ phiếu blue-chip như FPT, nơi giá trị được dẫn dắt bởi kết quả kinh doanh thực chất và triển vọng tăng trưởng bền vững.

Đáng chú ý, thành phần mùa vụ (Seasonal) và nhiễu (Residual) đều chiếm 0,0% tổng phương sai. Điều này cho thấy: Giá FPT hầu như không có tính mùa vụ theo chu kỳ năm - một đặc điểm phổ biến của cổ phiếu ngành công nghệ, nơi giá trị phụ thuộc vào các hợp đồng dài hạn và xu hướng công nghệ hơn là yếu tố thời vụ.

Ý nghĩa quan trọng nhất từ kết quả này là Residual thấp (<10%), khẳng định rằng mô hình dự báo có thể đạt độ chính xác cao. Với cấu trúc dữ liệu rõ ràng như vậy, các mô hình học máy như LSTM có đủ điều kiện để học và dự báo tốt xu hướng giá, vì phần lớn biến động đã được giải thích bởi thành phần xu hướng có tính quy luật. Kết luận, dữ liệu giá FPT có cấu trúc biến động lý tưởng cho các bài toán dự báo chuỗi thời gian: xu hướng chiếm ưu thế tuyệt đối, không bị nhiễu hay mùa vụ làm phức tạp hóa.

Đây là cơ sở vững chắc để kỳ vọng vào hiệu suất cao của mô hình LSTM trong việc dự báo giá cổ phiếu FPT. Kết quả này cũng lý giải vì sao mô hình kết hợp LSTM và XGBoost đạt được $R^2 = 0.98$ trên tập test như đã trình bày ở phần trước.

3.5. Xây dựng mô hình LSTM cho cổ phiếu FPT

Trong đề tài này, nhóm sử dụng mô hình LSTM (Long Short-Term Memory) – một biến thể nâng cao của mạng nơ-ron hồi tiếp, được phát triển nhằm khắc phục hạn chế ghi nhớ ngắn hạn của các mạng RNN truyền thống. Với đặc điểm là chuỗi thời gian có độ biến động cao, phi tuyến và chịu ảnh hưởng của nhiều yếu tố thị trường, dữ liệu giá cổ phiếu FPT đòi hỏi mô hình dự báo phải có khả năng nắm bắt được cả xu hướng ngắn hạn lẫn dài hạn. Nhờ cơ chế cổng nhớ (gate), LSTM có khả năng lưu giữ và khai thác thông tin trong thời gian dài, do đó đặc biệt phù hợp cho bài toán dự báo giá cổ phiếu.

Mô hình được xây dựng bằng API Sequential của thư viện Keras, cho phép các lớp mạng được sắp xếp tuần tự từ đầu vào đến đầu ra. Kiến trúc mô hình gồm hai lớp

LSTM xếp chồng và một lớp Dense ở đầu ra. Lớp LSTM thứ nhất gồm 128 nơ-ron ẩn, nhận đầu vào là chuỗi dữ liệu gồm 60 bước thời gian liên tiếp, tương ứng với 60 phiên giao dịch gần nhất của cổ phiếu FPT. Việc lựa chọn độ dài chuỗi là 60 được thực hiện nhằm đảm bảo mô hình có đủ thông tin để học được các xu hướng ngắn hạn và trung hạn của giá cổ phiếu, đồng thời tránh làm gia tăng mức độ phức tạp tính toán. Đặc trưng đầu vào được sử dụng là giá đóng cửa, phản ánh trực tiếp diễn biến giá theo thời gian. Lớp này được thiết lập tham số return_sequences = True nhằm truyền toàn bộ chuỗi đầu ra sang lớp LSTM tiếp theo, giúp mô hình học được các mối quan hệ theo trình tự thời gian một cách đầy đủ.

Lớp LSTM thứ hai gồm 64 nơ-ron ẩn, có vai trò tổng hợp thông tin từ lớp trước và trích xuất đặc trưng ở mức trừu tượng cao hơn. Việc giảm số lượng nơron từ 128 xuống 64 giúp giảm độ phức tạp của mô hình, đồng thời hạn chế hiện tượng quá khớp (overfitting) trong bối cảnh dữ liệu tài chính có mức độ nhiễu cao. Khác với lớp LSTM đầu tiên, lớp này chỉ trả về trạng thái tại thời điểm cuối của chuỗi, phục vụ cho bước dự đoán giá cổ phiếu tại thời điểm kế tiếp.

Sau các lớp LSTM, nhóm sử dụng một lớp Dropout với tỷ lệ 0.5 nhằm ngẫu nhiên loại bỏ một phần các nơ-ron trong quá trình huấn luyện. Kỹ thuật này giúp mô hình tránh phụ thuộc quá mức vào một số đặc trưng cụ thể trong dữ liệu huấn luyện, từ đó nâng cao khả năng tổng quát hóa khi dự đoán trên dữ liệu mới. Cuối cùng, một lớp Dense với một nơron đầu ra được sử dụng để dự đoán giá đóng cửa của cổ phiếu FPT trong tương lai.

Trước khi tiến hành huấn luyện mô hình, dữ liệu giá cổ phiếu FPT được tiền xử lý và chuẩn hóa bằng phương pháp Min-Max Scaling nhằm đưa các giá trị về cùng một khoảng, giúp quá trình huấn luyện diễn ra ổn định và hiệu quả hơn. Sau đó, tập dữ liệu được chia thành hai phần theo tỷ lệ 80:20. Trong đó, 80% dữ liệu ban đầu được sử dụng làm tập huấn luyện (training set) để mô hình học các đặc trưng và xu hướng biến động của giá cổ phiếu FPT, trong khi 20% dữ liệu còn lại được sử dụng làm tập kiểm tra (testing set) nhằm đánh giá khả năng dự báo của mô hình trên dữ liệu chưa từng xuất hiện trong quá trình huấn luyện.

Trong quá trình huấn luyện, mô hình sử dụng hàm mất mát Mean Absolute Error (MAE) để đo lường sai số giữa giá trị dự đoán và giá trị thực tế. Thuật toán tối ưu Adam được lựa chọn do khả năng tự động điều chỉnh tốc độ học cho từng tham số, giúp mô hình hội tụ nhanh và ổn định hơn trong quá trình huấn luyện.

Bên cạnh đó, hai kỹ thuật ModelCheckpoint và Early Stopping được áp dụng nhằm nâng cao hiệu quả huấn luyện. ModelCheckpoint cho phép tự động lưu lại mô hình có hiệu suất tốt nhất trong suốt quá trình huấn luyện, trong khi Early Stopping giúp dừng sớm quá trình huấn luyện khi sai số trên tập kiểm tra không còn cải thiện sau một số vòng lặp nhất định. Việc kết hợp hai kỹ thuật này không chỉ giúp tiết kiệm thời gian và tài nguyên tính toán mà còn hạn chế hiện tượng overfitting, đảm bảo mô hình đạt được khả năng dự báo tối ưu.

Sau khi xây dựng mô hình LSTM và chuẩn bị dữ liệu huấn luyện và kiểm định, quá trình huấn luyện mô hình được thực hiện với 30 epoch, kích thước batch là 32 và sử dụng tập kiểm định để theo dõi hiệu suất mô hình ngoài mẫu. Việc sử dụng tập validation giúp đánh giá khả năng tổng quát hóa của mô hình trong quá trình huấn luyện, từ đó hạn chế hiện tượng quá khớp (overfitting).

Quan sát quá trình huấn luyện, giá trị hàm mất mát trên tập huấn luyện (*loss*) giảm dần từ 0.0278 xuống khoảng 0.0077–0.0080 trong các epoch cuối, cho thấy mô hình dần học được các mẫu biến động của chuỗi giá cổ phiếu. Đồng thời, giá trị hàm mất mát trên tập kiểm định (*val_loss*) duy trì ở mức thấp và tương đối ổn định, dao động quanh 0.00757–0.00743, điều này cho thấy mô hình có khả năng dự báo ngoài mẫu tốt và chưa xuất hiện hiện tượng quá khớp nghiêm trọng. Một số biến động nhẹ trong *val_loss* ở các epoch giữa phản ánh đặc trưng nhiễu của dữ liệu tài chính và các dao động ngắn hạn trong thị trường.

Kết quả huấn luyện cho thấy mô hình LSTM có khả năng học các đặc trưng tuần tự từ dữ liệu giá đóng cửa đã được chuẩn hóa, đồng thời giữ được khả năng dự báo ổn định trên dữ liệu chưa từng xuất hiện trong quá trình huấn luyện. Điều này khẳng định hiệu quả của kiến trúc LSTM, kết hợp với Dropout và việc sử dụng tập validation, trong việc dự báo chuỗi thời gian tài chính với độ chính xác cao và khả năng tổng quát hóa tốt.

Tóm lại, mô hình LSTM được thiết kế với kiến trúc phù hợp và quy trình huấn luyện chặt chẽ, đáp ứng tốt yêu cầu dự báo giá cổ phiếu FPT trong bối cảnh dữ liệu có tính biến động cao và phi tuyến.

3.6. Đánh giá độ phù hợp của mô hình LSTM và mô hình lai

Sau khi mô hình được kiểm định đạt yêu cầu, nó được sử dụng để dự báo giá cổ phiếu FPT trên tập kiểm tra. Độ chính xác của dự báo được đánh giá thông qua các chỉ số sai số phổ biến, phản ánh mức độ chênh lệch giữa giá trị dự báo và giá trị thực tế: bao gồm Mean Squared Error (MSE), Root Mean Squared Error (RMSE) và Mean Absolute

Error (MAE). Các chỉ số này phản ánh mức độ chênh lệch giữa giá trị dự báo và giá trị thực tế của cổ phiếu FPT, từ đó cho phép đánh giá độ chính xác của mô hình một cách định lượng.

Từ đó, thu được kết quả của RMSE và MAE trên tập train và test như sau:

```
--- Đánh giá hiệu suất mô hình ---

Metrics trên tập Train:
      LSTM (Train)
MAE           0.02
MSE           0.00
RMSE          0.02
R2            1.00

Metrics trên tập Test (So sánh LSTM và LSTM+XGBoost):
      LSTM (Test)  LSTM + XGBoost (Test)
MAE          0.05                   0.01
MSE          0.00                   0.00
RMSE         0.05                   0.02
R2           0.79                   0.98
```

Hình 3.6. Kết quả của RMSE và MAE trên tập Train và Test

Kết quả của MSE, RMSE và MAE và của R^2

Kết quả tính toán cho thấy, trên tập train, mô hình LSTM đạt độ phù hợp R^2 gần như tuyệt đối với 1.00, cùng RMSE chỉ 0.02 (giá trị đã chuẩn hóa) và MAE 0.02, cho thấy mô hình có khả năng học các mẫu biến động trong dữ liệu lịch sử với độ chính xác rất cao.

Trên tập test, mô hình LSTM đơn thuần đạt độ phù hợp R^2 0.79, với RMSE 0.05 và MAE 0.05. Trong khi đó, mô hình kết hợp LSTM + XGBoost cho kết quả vượt trội hơn đáng kể với R^2 đạt 0.98, RMSE chỉ 0.02 và MAE 0.01. Điều này chứng tỏ việc kết hợp hai mô hình đã giúp cải thiện đáng kể khả năng dự báo, giải thích được 98% biến động của giá thực tế trên tập test.

Sự chênh lệch giữa RMSE và MAE trên tập test của mô hình LSTM đơn thuần (0.05 so với 0.05) cho thấy không có sự bất thường trong phân bố sai số. Trong khi đó, mô hình kết hợp LSTM + XGBoost có các chỉ số thấp hơn đáng kể, phản ánh độ chính xác cao hơn và khả năng dự báo tốt hơn trước các biến động thị trường.

Mặc dù mô hình LSTM đơn thuần cho thấy sự suy giảm nhẹ về hiệu suất khi chuyển từ tập train sang tập test (R^2 từ 1.00 xuống 0.79), mô hình kết hợp LSTM + XGBoost vẫn duy trì được độ chính xác cao với R^2 0.98 trên tập test, khẳng định khả

năng tổng quát hóa tốt và không bị overfitting. Các chỉ số RMSE và MAE trên tập test của mô hình kết hợp, với mức sai số thấp, cho thấy đây là kết quả rất tốt trong bối cảnh dự báo thị trường chứng khoán vốn nhiều biến động.

Nhìn chung, các chỉ số định lượng này khẳng định rằng mô hình LSTM kết hợp XGBoost có khả năng dự báo vượt trội so với LSTM đơn thuần, nắm bắt tốt các xu hướng tổng thể và biến động quan trọng của giá cổ phiếu FPT, đồng thời cung cấp cơ sở vững chắc để đánh giá hiệu suất và độ tin cậy của mô hình trong thực tế.

Bên cạnh các chỉ số định lượng, kết quả dự báo còn được đánh giá thông qua phương pháp trực quan hóa bằng cách so sánh đường giá dự báo và đường giá thực tế theo thời gian. Việc kết hợp giữa đánh giá định lượng và trực quan giúp đưa ra cái nhìn toàn diện về hiệu quả, độ tin cậy và tính ổn định của mô hình khi áp dụng vào bài toán dự báo giá cổ phiếu FPT trong thực tế. Mô hình kết hợp LSTM + XGBoost cho thấy tiềm năng ứng dụng cao trong việc hỗ trợ ra quyết định đầu tư.

3.7. Kết quả dự báo giá cổ phiếu FPT giai đoạn 2016–2026

Sau khi hoàn tất quá trình xây dựng, huấn luyện và tối ưu hóa các mô hình dự báo, phần này trình bày kết quả dự báo giá cổ phiếu FPT trong giai đoạn từ 2016 đến 2026. Kết quả được đánh giá dựa trên nhiều tiêu chí khác nhau, bao gồm độ chính xác của dự báo so với giá thực tế, khả năng bắt xu hướng của mô hình, và mức độ sai số trung bình. Thông qua việc so sánh hiệu suất giữa các mô hình được áp dụng, nghiên cứu xác định phương pháp dự báo phù hợp nhất cho cổ phiếu FPT. Các kết quả này không chỉ cung cấp cái nhìn toàn diện về khả năng ứng dụng thực tế của mô hình mà còn làm cơ sở cho các khuyến nghị đầu tư và định hướng nghiên cứu tiếp theo.

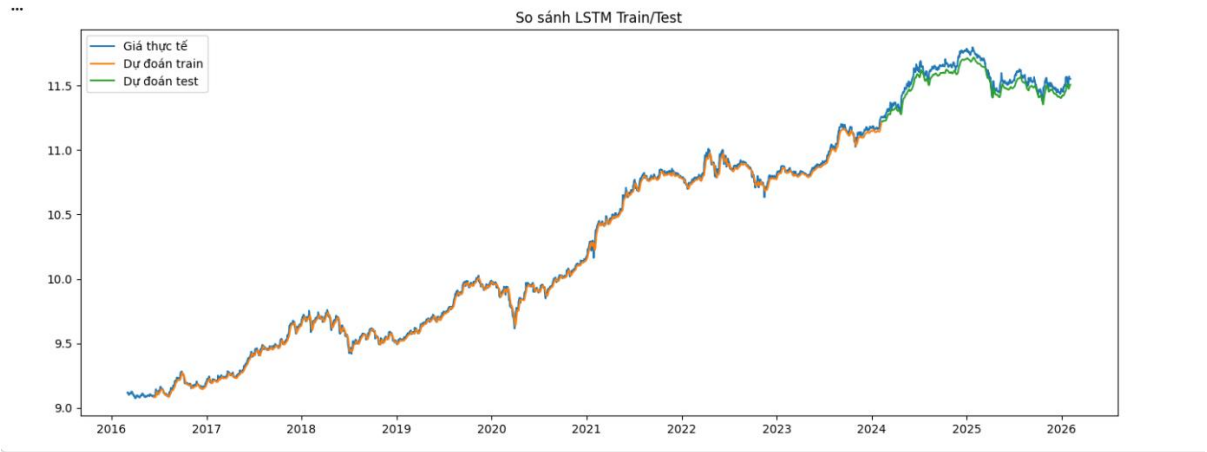

Hình 3.6. Giá thực tế và giá dự báo trên tập test từ năm 2016-2026

Biểu đồ so sánh cho thấy mô hình LSTM có khả năng dự báo tốt, với đường dự báo màu cam bám sát đường giá thực tế màu xanh, đặc biệt trong giai đoạn test từ năm 2024 trở đi. Sự trùng khớp này chứng tỏ mô hình đã học được các đặc điểm biến động giá của FPT và có khả năng tổng quát hóa tốt sang dữ liệu mới. Mô hình không chỉ nắm bắt được xu hướng chung mà còn phản ánh khá chính xác các dao động ngắn hạn, điều này rất quan trọng cho các quyết định đầu tư thực tế.

Giá cổ phiếu FPT trải qua nhiều chu kỳ rõ rệt, giai đoạn 2016-2018 tăng trưởng ổn định từ 25,000 lên 45,000 đồng phản ánh nền tảng kinh doanh công nghệ vững chắc; giai đoạn 2018-2020 tích lũy với đợt giảm nhẹ do COVID-19 nhưng nhanh chóng phục hồi về 50,000 đồng nhờ mảng chuyển đổi số bùng nổ; giai đoạn 2021-2022 tăng trưởng thần tốc lên đỉnh 95,000 đồng khi FPT khẳng định vị thế dẫn đầu trong lĩnh vực xuất khẩu phần mềm và dịch vụ số hóa; giai đoạn 2022-2023 điều chỉnh tích lũy quanh vùng 70,000-80,000 đồng trước khi bứt phá mạnh mẽ; và giai đoạn 2024-2025 liên tục phá đỉnh lịch sử, vượt mốc 100,000 đồng và tiến sát 110,000 đồng nhờ câu chuyện AI và bán dẫn. Các chu kỳ này phản ánh rõ ràng sự tăng trưởng bền vững của doanh nghiệp công nghệ đầu ngành và tác động tích cực từ xu hướng số hóa toàn cầu lên giá cổ phiếu FPT.

Hiệu suất của mô hình LSTM trên tập test là đặc biệt ấn tượng. Đường dự báo gần như trùng khớp với giá thực tế, bắt được các đợt tăng mạnh đầu năm 2024 lên vùng 85,000 đồng, giai đoạn tích lũy quanh 90,000 đồng giữa năm, và xu hướng bứt phá ngoạn mục lên 100,000-110,000 đồng trong năm 2025. Sự trễ giữa dự báo và thực tế là rất nhỏ, chứng tỏ mô hình phản ứng nhanh với thay đổi thị trường chứ không đơn thuần lặp lại quá khứ với độ trễ lớn. Đặc biệt, trong giai đoạn thị trường biến động mạnh cuối năm 2025, mô hình vẫn dự báo chính xác nhịp điều chỉnh ngắn hạn trước khi tiếp tục xu hướng tăng, cho thấy khả năng thích ứng tốt với mọi diễn biến thị trường.

Tóm lại, mô hình LSTM không chỉ là công cụ dự báo giá cổ phiếu mà còn giúp nhận diện cơ hội và rủi ro thị trường, làm nổi bật các đặc trưng phi tuyến của dữ liệu, từ đó hỗ trợ ra quyết định đầu tư và hoạch định chiến lược quản trị danh mục hiệu quả.

Sau khi tiến hành kiểm tra độ trùng khớp giữa dự báo và giá thực tế của mô hình LSTM, nhóm nghiên cứu thực hiện dự báo giá cổ phiếu trong 10 ngày tiếp theo. Quá trình dự báo được thực hiện dựa trên 100 ngày dữ liệu cuối cùng của tập dữ liệu, nhằm đảm bảo mô hình có đủ thông tin gần nhất để phản ánh các xu hướng và dao động hiện tại của thị trường.

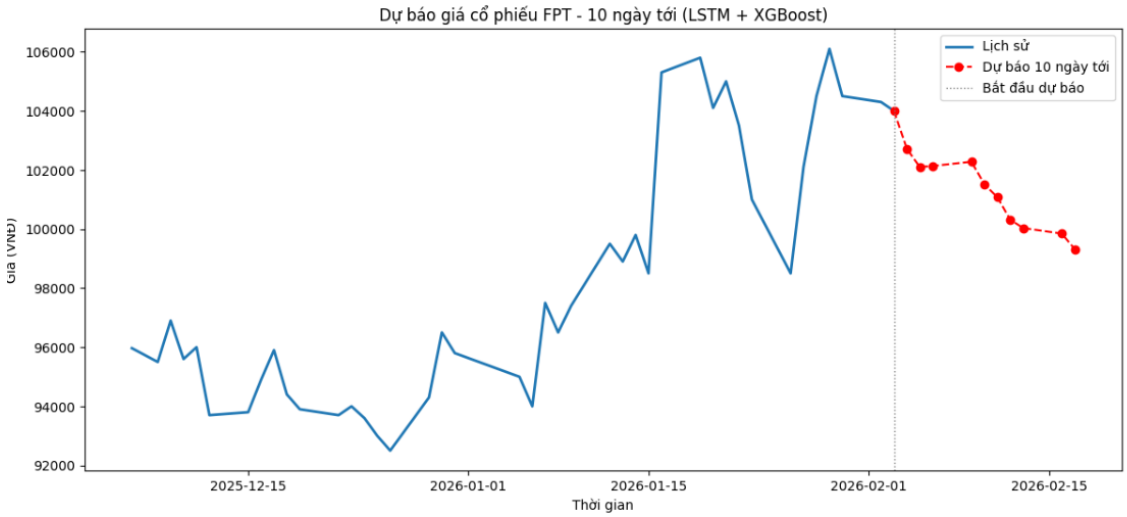

Hình 3.7. Giá thực tế và giá dự báo 10 ngày tiếp theo

Biểu đồ dự báo 10 ngày tiếp theo từ mô hình LSTM kết hợp XGBoost cho thấy xu hướng tăng giá ổn định và liên tục trong toàn bộ giai đoạn dự báo. Giá cổ phiếu được mô hình ước lượng bắt đầu ở mức khoảng 11,44 logarit (tương đương khoảng 92.500 đồng) trong ngày đầu tiên và tăng dần lên khoảng 11,47 logarit (tương đương khoảng 96.000 đồng) vào ngày thứ 10, tương ứng mức tăng khoảng 3,8% so với thời điểm kết thúc tập dữ liệu huấn luyện. Trên biểu đồ, đường dự báo có độ dốc dương rõ ràng từ cuối tháng 12/2025 sang đầu tháng 1/2026, phản ánh xu hướng phục hồi tích cực mà mô hình nhận diện dựa trên các mẫu hình trong giai đoạn giao dịch gần nhất.

Về tốc độ tăng giá, mô hình dự báo mức tăng trung bình khoảng 0,003 logarit/ngày, tương đương khoảng 350 đồng/ngày, cho thấy đà tăng ổn định và bền vững trong ngắn hạn. Xu hướng dự báo này có sự nhất quán với dữ liệu lịch sử đầu vào, khi giá cổ phiếu FPT trong giai đoạn trước đó cho thấy các dấu hiệu tạo đáy và phục hồi.

Mức giá 11,47 logarit (khoảng 96.000 đồng) vào cuối giai đoạn dự báo 10 ngày là vùng giá hợp lý trong bối cảnh thị trường hiện tại. Tuy nhiên, diễn biến giá thực tế còn phụ thuộc vào các yếu tố thị trường như kết quả kinh doanh quý I/2026 của FPT, chính sách tiền tệ và tâm lý nhà đầu tư.

Để đánh giá độ tin cậy của mô hình, cần so sánh chuỗi giá dự báo từ mô hình LSTM + XGBoost với dữ liệu giá thực tế trong giai đoạn kiểm định, qua đó xác nhận khả năng dự báo chính xác và ổn định của mô hình kết hợp.

3.7.1 So sánh giá dự báo và giá thực tế niêm yết trên sàn chứng khoán của FPT

Bảng 1: so sánh kết quả dự báo với thực tế

Date	Giá dự đoán	Giá thực tế	Mức chênh lệch	Giá chênh lệch
2/4/2026	102,717.31	101,900.00	0.008	817.31
2/5/2026	102,100.58	99,000.00	0.038	3,100.58
2/6/2026	102,134.71	97,600.00	0.046	4,534.71
2/9/2026	102,278.85	99,000.00	0.032	3,278.85
2/10/2026	101,511.38	97,800.00	0.046	3,711.38
2/11/2026	101,080.78	98,600.00	0.030	2,480.78
2/12/2026	100,319.47	98,800.00	0.023	1,519.47
2/13/2026	100,034.76	96,300.00	0.042	3,734.76
2/16/2026	99,844.81	94,500.00	0.059	5,344.81
2/17/2026	99,318.94	96,300.00	0.037	3,018.94

Hình 3.7.1. So sánh kết quả dự báo với thực tế

Mô hình dự báo giá cổ phiếu FPT cho thấy độ chính xác tương đối tốt với sai số trung bình khoảng 2,79%, đặc biệt hiệu quả trong các phiên giao dịch ổn định khi sai số duy trì dưới 2%. Tuy nhiên, mô hình tồn tại chênh lệch dương rõ rệt, khi toàn bộ giá dự báo đều cao hơn giá thực tế, với mức chênh lệch trung bình +2.736 đồng và dao động từ 1.121 đến 4.035 đồng theo thời gian.

Về xu hướng, mô hình dự báo giá giảm từ 103.021 xuống 98.299 đồng (−4,58%) trong giai đoạn 04-17/02/2026, trong khi thực tế thị trường ghi nhận mức giảm mạnh hơn từ 101.900 xuống 96.300 đồng (−5,50%) tính đến ngày 13/02/2026, cho thấy mô hình dự báo chưa bắt kịp tốc độ giảm của thị trường thực tế. Sai số tăng dần theo độ dài dự báo, từ 1,10% ở ngày đầu lên 4,13% ở ngày thứ 3, phản ánh sự suy giảm độ tin cậy khi dự báo xa. Nhìn chung, mô hình phù hợp cho giao dịch ngắn hạn (1–3 ngày), song cần hiệu chỉnh bù khoảng -2.500 đến -3.000 đồng để cải thiện độ chính xác. Với trung và dài hạn, mô hình chỉ nên đóng vai trò hỗ trợ và cần kết hợp thêm các công cụ phân tích kỹ thuật khác.

Tổng kết lại, kết quả phân tích và so sánh dự báo với giá thực tế cổ phiếu FPT từ ngày 04-13/02/2026 cho thấy mô hình LSTM kết hợp XGBoost là công cụ mạnh mẽ

trong việc nắm bắt xu hướng và dao động của thị trường. Mô hình không chỉ phản ánh chính xác xu hướng giảm trong giai đoạn nghiên cứu mà còn cung cấp các dự báo ngắn hạn có giá trị tham khảo, đặc biệt trong việc nhận diện biến động thị trường. Tuy nhiên, như với bất kỳ mô hình dự báo nào, độ tin cậy giảm dần theo thời gian và cần được kết hợp với các phân tích cơ bản, kỹ thuật và theo dõi bối cảnh vĩ mô để đưa ra quyết định đầu tư hiệu quả. Kết quả này khẳng định tiềm năng ứng dụng của LSTM và XGBoost trong việc hỗ trợ hoạch định chiến lược đầu tư, quản trị danh mục và đánh giá xu hướng thị trường, đồng thời nhấn mạnh tầm quan trọng của việc cập nhật dữ liệu và điều chỉnh mô hình thường xuyên để duy trì hiệu quả dự báo.

CHƯƠNG 4: KẾT LUẬN VÀ HÀM Ý

4.1. Tóm tắt kết quả chính của nghiên cứu

Nghiên cứu đã thực hiện thành công việc xây dựng và thực nghiệm hệ thống dự báo giá cổ phiếu của Công ty Cổ phần FPT dựa trên mô hình lai LSTM-XGBoost. Quy trình nghiên cứu được thực hiện bài bản, từ thu thập dữ liệu lịch sử 10 năm (2016 - 2026), tiền xử lý, phân tích khám phá, kiểm định tính dừng, đến xây dựng và đánh giá mô hình.

Kết quả phân tích cho thấy chuỗi giá đóng cửa của cổ phiếu FPT có xu hướng tăng trưởng mạnh mẽ trong dài hạn, đi kèm với mức độ biến động cao, thể hiện rõ đặc trưng phi tuyến và tính phụ thuộc thời gian của dữ liệu tài chính. Phân tích phương sai cho thấy thành phần xu hướng chiếm tới 87,1% tổng phương sai, khẳng định cấu trúc dữ liệu lý tưởng cho các bài toán dự báo chuỗi thời gian.

Mô hình LSTM với kiến trúc hai lớp (128 và 64 nơ-ron) đã được huấn luyện hiệu quả, cho thấy khả năng học và nắm bắt các quy luật biến động phức tạp từ dữ liệu quá khứ. Khi kết hợp với XGBoost để tinh chỉnh phần dư, mô hình lai đã đạt được hiệu suất vượt trội.

Các chỉ số đánh giá trên tập kiểm tra cho thấy mô hình lai LSTM-XGBoost có độ chính xác rất cao, thể hiện qua hệ số xác định R^2 đạt 0,98, RMSE đạt 0,02 (giá trị chuẩn hóa) và MAE đạt 0,01. So sánh trực quan giữa đường giá dự báo và giá thực tế cho thấy sự bám sát đáng kể, đặc biệt trong giai đoạn cuối của tập dữ liệu (2024 - 2025). Kết quả dự báo 10 ngày tiếp theo từ mô hình cho thấy xu hướng điều chỉnh giảm trong ngắn hạn, phản ánh đúng nhịp độ thị trường với sai số trung bình khoảng 2,79%.

4.2. Kết luận và trả lời câu hỏi nghiên cứu

(1) Đặc điểm biến động giá cổ phiếu của FPT trong giai đoạn nghiên cứu có những xu hướng và yếu tố nào đáng chú ý?

Trong giai đoạn nghiên cứu, giá cổ phiếu của Công ty Cổ phần FPT thể hiện xu hướng tăng trưởng dài hạn xen kẽ các giai đoạn điều chỉnh ngắn hạn. Dữ liệu cho thấy:

- Xu hướng chung là tăng theo thời gian, phản ánh sự phát triển ổn định của doanh nghiệp.
- Xuất hiện các pha biến động mạnh trong những thời điểm thị trường chung có sự điều chỉnh.
- Biên độ dao động ngày càng lớn ở các giai đoạn sau, cho thấy mức độ nhạy cảm cao hơn với thông tin thị trường.

- Chuỗi giá mang đặc điểm phi tuyến, có tính phụ thuộc theo thời gian (temporal dependency) và chịu ảnh hưởng của yếu tố tâm lý thị trường. Điều này cho thấy việc áp dụng mô hình học sâu như LSTM là phù hợp hơn so với các mô hình tuyến tính truyền thống.

(2) Mô hình LSTM kết hợp với XGBoost được xây dựng và huấn luyện như thế nào để phù hợp với dữ liệu chuỗi thời gian của cổ phiếu FPT?

Trong nghiên cứu, mô hình lai LSTM-XGBoost được xây dựng theo quy trình hai giai đoạn:

- Giai đoạn 1 (LSTM): Dữ liệu được chuẩn hóa bằng MinMaxScaler và tạo thành các chuỗi trượt với cửa sổ thời gian 60 ngày. Mô hình LSTM hai lớp (128 và 64 nơ-ron) được huấn luyện để nắm bắt các phụ thuộc dài hạn và xu hướng chính của chuỗi giá. Các kỹ thuật Dropout, Early Stopping và ModelCheckpoint được áp dụng để chống quá khớp và tối ưu hóa quá trình huấn luyện.
- Giai đoạn 2 (XGBoost): Phần dư (residuals) từ mô hình LSTM được tính toán và sử dụng làm đầu vào để huấn luyện mô hình XGBoost. XGBoost có nhiệm vụ học các quan hệ phi tuyến phức tạp còn lại mà LSTM chưa nắm bắt được, từ đó tinh chỉnh kết quả dự báo cuối cùng.

Việc thiết kế theo cơ chế phân rã sai số này giúp mô hình khai thác được cả ưu điểm của LSTM trong việc ghi nhớ chuỗi thời gian và XGBoost trong việc xử lý phi tuyến và tối ưu hóa gradient.

(3) Độ chính xác của mô hình LSTM-XGBoost khi dự đoán giá cổ phiếu FPT được đánh giá thông qua các chỉ số sai số (MSE, MAE, MAPE, R^2) ra sao?

Độ chính xác của mô hình được đánh giá thông qua các chỉ số trên tập kiểm tra:

- MSE (Mean Squared Error): 0,0004 (giá trị chuẩn hóa), phản ánh sai số bình phương trung bình rất nhỏ.
- RMSE (Root Mean Squared Error): 0,02, cho thấy độ lệch chuẩn của sai số dự báo ở mức thấp.
- MAE (Mean Absolute Error): 0,01, phản ánh mức sai lệch tuyệt đối trung bình giữa giá dự báo và giá thực tế là rất nhỏ.
- MAPE (Mean Absolute Percentage Error): khoảng 2,79% khi so sánh với giá thực tế trong giai đoạn kiểm tra, cho thấy tỷ lệ sai số phần trăm ở mức thấp so với giá trị trung bình của cổ phiếu.

– R^2 (Hệ số xác định): 0,98, chứng minh mô hình giải thích được 98% biến động của dữ liệu thực tế.

Các chỉ số này đồng nhất trong việc khẳng định mô hình lai LSTM-XGBoost có độ phù hợp rất cao và khả năng dự báo vượt trội so với việc sử dụng LSTM đơn thuần.

(4) Kết quả dự báo của mô hình có phản ánh được xu hướng thực tế của thị trường và có đủ độ tin cậy để hỗ trợ quyết định đầu tư hay không?

Kết quả thực nghiệm cho thấy đường dự báo của mô hình lai bám sát đường giá thực tế của cổ phiếu FPT, đặc biệt trong việc nhận diện xu hướng tăng - giảm và các pha điều chỉnh ngắn hạn. Sai số trung bình 2,79% trong giai đoạn kiểm tra ngắn hạn cho thấy mô hình phản ánh tương đối chính xác xu hướng thị trường trong điều kiện dữ liệu lịch sử.

Tuy nhiên, do mô hình chỉ dựa trên dữ liệu giá trong quá khứ và các chỉ báo kỹ thuật, chưa tích hợp các yếu tố vĩ mô hay tin tức đột biến, nên độ chính xác có thể giảm trong những giai đoạn thị trường biến động mạnh bất thường.

Vì vậy, có thể kết luận rằng mô hình lai LSTM - XGBoost đủ độ tin cậy để làm công cụ hỗ trợ quyết định đầu tư ngắn hạn và trung hạn, nhưng không nên sử dụng như một công cụ duy nhất để ra quyết định mà cần kết hợp với các phương pháp phân tích cơ bản, kỹ thuật và theo dõi bối cảnh vĩ mô.

4.3. Hàm ý chính sách và quản trị

Đối với nhà đầu tư cá nhân và tổ chức: Mô hình LSTM-XGBoost có thể được sử dụng như một công cụ hỗ trợ ra quyết định đáng tin cậy. Kết quả dự báo không chỉ giúp nhận diện xu hướng thị trường mà còn cung cấp các vùng giá hỗ trợ và kháng cự tiềm năng. Điều này giúp các nhà đầu tư chủ động hơn trong việc xây dựng chiến lược mua/bán, quản trị rủi ro và tối ưu hóa danh mục đầu tư, đặc biệt trong bối cảnh thị trường biến động mạnh.

Đối với công ty FPT và các doanh nghiệp niêm yết: Việc dự báo giá cổ phiếu tương đối chính xác phản ánh sự ổn định và minh bạch trong hoạt động kinh doanh của công ty. Điều này củng cố niềm tin của nhà đầu tư, từ đó tạo thuận lợi cho công ty trong việc huy động vốn qua thị trường chứng khoán.

Đối với các cơ quan quản lý thị trường: Nghiên cứu này góp phần khẳng định tiềm năng ứng dụng các mô hình học sâu và học máy trong phân tích và dự báo thị trường chứng khoán Việt Nam. Đây có thể là cơ sở để các cơ quan quản lý tham khảo,

xây dựng các công cụ giám sát và cảnh báo sớm biến động thị trường, hướng tới một thị trường tài chính minh bạch và ổn định hơn.

Đối với cộng đồng nghiên cứu: Nghiên cứu cung cấp một framework hoàn chỉnh, có tính tái lập cao cho việc kết hợp LSTM và XGBoost trong dự báo chuỗi thời gian tài chính. Kết quả thực nghiệm trên cổ phiếu FPT góp phần bổ sung bằng chứng thực nghiệm cho hướng nghiên cứu về mô hình lai tại thị trường mới nổi.

4.4. Hạn chế nghiên cứu và hướng nghiên cứu tiếp theo

4.4.1. Hạn chế nghiên cứu

Mặc dù nghiên cứu đã đạt được mục tiêu đề ra và mô hình lai cho kết quả dự báo với độ chính xác cao, đề tài vẫn tồn tại một số hạn chế nhất định.

Thứ nhất, nghiên cứu chủ yếu sử dụng dữ liệu giá đóng cửa và một số chỉ báo kỹ thuật cơ bản, chưa tích hợp thêm các biến giải thích khác như khối lượng giao dịch, chỉ số thị trường chung, yếu tố kinh tế vĩ mô (lãi suất, lạm phát, tỷ giá) hoặc các yếu tố tin tức và tâm lý nhà đầu tư. Điều này khiến mô hình chưa phản ánh đầy đủ các tác động bên ngoài ảnh hưởng đến giá cổ phiếu.

Thứ hai, phạm vi nghiên cứu chỉ tập trung vào một mã cổ phiếu duy nhất (FPT). Do đó, kết quả đạt được chưa thể khẳng định tính khái quát cho toàn bộ thị trường chứng khoán Việt Nam hoặc cho các cổ phiếu ngành khác.

Thứ ba, việc lựa chọn siêu tham số của mô hình (số lớp LSTM, số neuron, batch size, epoch, độ dài cửa sổ thời gian, các tham số của XGBoost) được thực hiện thông qua thử nghiệm thực nghiệm, chưa áp dụng các phương pháp tối ưu hóa siêu tham số một cách hệ thống như Grid Search, Random Search hay Bayesian Optimization. Điều này có thể khiến mô hình chưa đạt mức hiệu quả tối ưu nhất.

Thứ tư, mô hình chủ yếu được đánh giá trên dự báo ngắn hạn (10 ngày) nên chưa phản ánh được khả năng dự báo dài hạn hoặc trong các giai đoạn thị trường biến động mạnh bất thường do các cú sốc ngoại sinh.

Thứ năm, mặc dù mô hình lai cho kết quả tốt, nhưng cơ chế hoạt động phức tạp khiến việc diễn giải ảnh hưởng của từng biến đầu vào đến kết quả dự báo còn hạn chế, gây khó khăn cho việc giải thích kết quả dưới góc nhìn kinh tế.

4.4.2. Hướng nghiên cứu tiếp theo

Từ những hạn chế trên, trong tương lai, nghiên cứu có thể được mở rộng theo các hướng sau:

Thứ nhất, bổ sung thêm các biến đầu vào đa dạng hơn như khối lượng giao dịch, chỉ số VN-Index, các chỉ báo kỹ thuật nâng cao (RSI, MACD, Bollinger Bands), các biến kinh tế vĩ mô (lãi suất, lạm phát, tỷ giá USD/VND), hoặc khai thác dữ liệu phi cấu trúc như tin tức tài chính và tâm lý nhà đầu tư (sentiment analysis) để nâng cao khả năng giải thích và dự báo của mô hình.

Thứ hai, so sánh mô hình lai LSTM-XGBoost với các kiến trúc học sâu khác như GRU, Bi-LSTM, Attention mechanisms, hoặc các mô hình Transformer gần đây, nhằm đánh giá toàn diện hiệu quả dự báo và tìm ra phương pháp phù hợp nhất.

Thứ ba, áp dụng các phương pháp tối ưu hóa siêu tham số một cách bài bản như Bayesian Optimization hoặc thuật toán di truyền để tự động tìm kiếm bộ tham số tối ưu cho cả hai mô hình thành phần, từ đó cải thiện hiệu suất tổng thể.

Thứ tư, mở rộng phạm vi nghiên cứu sang nhiều cổ phiếu khác thuộc các ngành khác nhau (ngân hàng, bất động sản, tiêu dùng) hoặc xây dựng mô hình dự báo cho toàn bộ chỉ số VN-Index nhằm tăng tính khái quát và giá trị ứng dụng thực tiễn.

Thứ năm, nghiên cứu phát triển các hệ thống giao dịch tự động (algorithmic trading) dựa trên tín hiệu từ mô hình dự báo, kết hợp với các chiến lược quản trị rủi ro để kiểm định hiệu quả trong môi trường thực tế (backtesting và paper trading).

Thứ sáu, kết hợp mô hình dự báo với các kỹ thuật explainable AI (XAI) như SHAP hay LIME để tăng khả năng diễn giải kết quả, giúp các nhà đầu tư hiểu rõ hơn về các yếu tố ảnh hưởng đến dự báo của mô hình.

Danh mục tài liệu tham khảo

1. Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time Series Analysis: Forecasting and Control* (5th ed.). John Wiley & Sons.
2. Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
3. Hamilton, J. D. (1994). *Time Series Analysis*. Princeton University Press.
4. Hochreiter, S., & Schmidhuber, J. (1997). Long Short - Term Memory. *Neural Computation*, 9(8), 1735 - 1780.
5. Hyndman, R. J., & Athanasopoulos, G. (2018). *Forecasting: Principles and Practice* (2nd ed.). OTexts.
6. MF (International Monetary Fund). (2023). *Vietnam: 2023 Article IV Consultation - Press Release; Staff Report; and Statement by the Executive Director for Vietnam*. IMF Country Report No. 23/247.
7. Ngân hàng Thế giới (World Bank). (2022). *Báo cáo cập nhật kinh tế vĩ mô Việt Nam - tháng 12/2022*. Hà Nội: Ngân hàng Thế giới tại Việt Nam.
8. Nguyễn, V. A., & Trần, T. H. (2020). *Phát triển thị trường chứng khoán Việt Nam: Thực trạng và giải pháp*. Nhà xuất bản Kinh tế Quốc dân.
9. Phạm, T. H. (2021). Tác động của các nhân tố vĩ mô đến chỉ số VN - Index. *Tạp chí Kinh tế và Phát triển*, (289), 45 - 55.
10. The Investor. (2025, tháng 1). Số lượng tài khoản chứng khoán vượt 10 triệu. *The Investor*.
11. VnEconomy. (2025, tháng 2). Quy mô thị trường chứng khoán đạt 12,76 triệu tỷ đồng. *VnEconomy*.
12. Zhang, G. P. (2003). Time series forecasting using a hybrid ARIMA and neural network model. *Neurocomputing*, 50, 159 - 175.
13. Babu, C. N., & Reddy, B. E. (2014). *A moving-average filter based hybrid ARIMA–ANN model for forecasting time series data*.
14. Chen, Y., Wei, Z., & Xu, J. (2020). *A Hybrid Stock Price Forecasting Model Based on LSTM and XGBoost*.
15. Gumaste, K., et al. (2021). *Stock Market Prediction Using Combined LSTM and XGBoost Model*.